



**UNIVERSIDAD
DE GRANADA**

E.T.S. de Ingenierías Informática y de Telecomunicación

**MÁSTER EN CIENCIA DE DATOS E INGENIERÍA DE
COMPUTADORES**

TRABAJO FIN DE MÁSTER

**Segmentación de especies de arbustos
polimorfos de alta montaña en imágenes
aéreas: explotar los sesgos de las
CNNs**

Presentado por:
D^a. Ana Fuentes Rodríguez

Tutorizado por:
D^a. Siham Tabik Ouled Hrouir

Curso Académico 2025/2026

Resumen

El mapeo automático de especies arbustivas sentinela como *Juniperus* en imágenes aéreas o satelitales es crucial para el correcto seguimiento de ecosistemas de alta montaña; sin embargo, esto alberga a su vez una gran complejidad debido a múltiples factores. En primer lugar, el proceso de obtención de datos anotados ha de realizarse de forma manual, lo que resulta muy laborioso y costoso, limitando por ello la cantidad de conjuntos de datos disponibles lo suficientemente amplios. En segundo lugar, no existen bases de datos públicas centradas en la detección de arbustos, sino que los pocos recursos disponibles se orientan a árboles, que presentan mayor tamaño y, adicionalmente, se anotan mediante formatos heterogéneos como puntos centrales o bounding boxes. En tercer lugar, no está claro qué métodos de detección resultan ser los más adecuados para la identificación de arbustos individuales en este tipo de imágenes. Por último, todos estos inconvenientes se acentúan ante el hecho de trabajar con imágenes satelitales, ya que la resolución espacial, la variabilidad espectral y la textura del terreno añaden un nivel adicional de ruido y ambigüedad respecto a las imágenes naturales. Este Trabajo Fin de Máster se desarrolla en el contexto del primer conjunto de datos específicamente generado para la detección y mapeo automáticos de *Juniperus* en imágenes satelitales. En este trabajo se aborda el problema como una tarea de segmentación y se analizan diferentes arquitecturas, tanto de segmentación de instancias como semántica, incluyendo los modelos Mask R-CNN, DeepLabV3+, PanopticFPN y PointRend (en sus variantes de instancias y semántica). Dado que las CNN presentan un sesgo hacia la textura frente a la forma, y considerando que *Juniperus* muestra una gran variabilidad morfológica, se investiga qué elementos arquitecturales favorecen una detección robusta basada en patrones de textura. Los resultados muestran que Mask R-CNN, un modelo clásico y ampliamente utilizado, ofrece el rendimiento más consistente en este escenario, superando así a las arquitecturas semánticas en la identificación individual de arbustos. El desarrollo y configuración de todos los modelos estudiados se encuentran en este link^a.

Palabras clave: Segmentación, arbustos polimórficos, imágenes de satélites, aprendizaje profundo, visión por computador, redes neuronales convolucionales.

^ahttps://github.com/AnaFueRo/TFM-Juniper_Models/tree/main/Models

Abstract

Automatic mapping of sentinel shrub species like *Juniperus* in aerial or satellite imagery is crucial for the accurate monitoring of high-mountain ecosystems; however, this process is highly complex due to several factors. First, obtaining annotated data must be done manually, which is laborious and costly, thus limiting the number of sufficiently large datasets available. Second, there are no public databases focused on shrub detection; the few available resources are geared towards trees, which are larger and are annotated using heterogeneous formats such as center points or bounding boxes. Third, it is unclear which detection methods are best suited for identifying individual shrubs in this type of imagery. Finally, all these drawbacks are accentuated when working with satellite images, since spatial resolution, spectral variability, and terrain texture add an additional level of noise and ambiguity compared to natural images.

This Master's thesis is developed within the context of the first dataset specifically generated for the automatic detection and mapping of *Juniperus* in satellite imagery. This work addresses the problem as a segmentation task and analyzes different architectures for both instance and semantic segmentation, including the Mask R-CNN, DeepLabV3+, PanopticFPN, and PointRend models (in their instance and semantic variants). Given that CNNs exhibit a bias towards texture over form, and considering that *Juniperus* displays significant morphological variability, the research investigates which architectural elements favor robust detection based on texture patterns. The results show that Mask R-CNN, a classic and widely used model, offers the most consistent performance in this scenario, thus outperforming semantic architectures in the individual identification of shrubs. The development and configuration of all the models studied can be found at this link^a.

Keywords: Segmentation, polymorphic bushes, satellite imagery, deep learning, computer vision, convolutional neural networks.

^ahttps://github.com/AnaFueRo/TFM-Juniper_Models/tree/main/Models

Yo, **Ana Fuentes Rodríguez**, con DNI **77379824G**, declaro que soy la única autora del Trabajo Fin de Máster titulado **“Segmentación de especies de arbustos polimorfos de alta montaña en imágenes aéreas: explotar los sesgos de las CNNs”**, que el trabajo no incumple con la ley de propiedad intelectual y que todo material no original de este trabajo ha sido atribuido a sus autores legítimos.

Fdo: **Ana Fuentes Rodríguez**

Granada, a 11 de diciembre de 2025

D^a. **Siham Tabik**, Profesora del área de *Soft Computing and Intelligent Information Systems* del *Departamento de Ciencias de la Computación e Inteligencia Artificial* de la Universidad de Granada.

Informa:

Que el presente trabajo, titulado “**Segmentación de especies de arbustos polimorfos de alta montaña en imágenes aéreas: explotar los sesgos de las CNNs**”, ha sido realizado bajo su supervisión por **Ana Fuentes Rodríguez**, y autoriza la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expido y firmo el presente informe en Granada a 11 de diciembre de 2025.

La directora:

Fdo: **Siham Tabik**

Índice

1	Introducción	8
1.1	Contexto ecológico y ambiental	8
1.2	Motivación y relevancia del estudio	9
1.3	Problemática de la detección de especies polimorfas	10
1.4	Estado actual de la teledetección y la visión por computador en ecología	12
1.4.1	Evolución de los métodos de teledetección en ecología	12
1.4.2	Aplicación de la visión por computador y el deep learning	12
1.4.3	Oportunidades y desafíos	13
1.4.4	Relevancia para el presente estudio	13
1.5	Objetivos generales y específicos del TFM	14
1.6	Estructura del documento	15
2	Marco bibliográfico	16
2.1	Introducción al deep learning en teledetección	16
2.2	Evolución cronológica de los modelos de segmentación profunda	17
2.3	Aplicaciones de los modelos de segmentación en teledetección y ecología	19
2.3.1	Mask R-CNN: teledetección y ecología	19
2.3.2	DeepLabV3+: segmentación semántica en vegetación y coberturas	20
2.3.3	PointRend: refinamiento de bordes en ecosistemas complejos	20
2.3.4	Panoptic FPN: visión integral del paisaje	20
2.3.5	Síntesis general	21
2.4	Comparativa crítica y limitaciones de los enfoques de segmentación en ecología	21
3	Área de estudio y conjunto de datos	23
3.1	Descripción del área de estudio: Sierra Nevada	23
3.2	Conjunto de datos. JuniperMapper: AI for Shrub Delineation (DATA)	25
3.2.1	Photo Interpretation Data (PI)	25
3.2.2	Field Work Data (FW)	26
3.2.3	Análisis descriptivo de tamaños y cobertura	26
3.2.4	Visualización de ejemplos	27
4	Metodología	27
4.1	Visión general del flujo de trabajo	27
4.2	Preparación de datos	31
4.2.1	Conversión de anotaciones y generación de máscaras semánticas	31
4.2.2	Registro de los datasets en Detectron2	31
4.2.3	Estandarización de tamaño y resolución	32
4.2.4	Normalización radiométrica y preprocesado fotométrico	32
4.2.5	Esquemas de data augmentation	33
4.2.6	Preprocesado específico por tipo de modelo	34
4.3	Modelos de segmentación	34
4.3.1	Mask R-CNN (baseline del artículo original)	35
4.3.2	PointRend (segmentación de instancias)	35
4.3.3	DeepLabV3+ (segmentación semántica)	36
4.3.4	PointRend-Semántico (segmentación semántica)	37

4.3.5	Panoptic FPN (segmentación panóptica)	37
4.3.6	Resumen comparativo de configuraciones	38
4.4	Evaluación y métricas	39
4.4.1	Métricas a nivel de instancia	40
4.4.2	Métricas a nivel de píxel	40
4.4.3	Selección del umbral óptimo θ^*	41
4.4.4	Métricas espaciales: cobertura y densidad	41
4.4.5	Posprocesado: segmentación por watershed (WS)	42
4.4.6	Criterios comparativos y resumen de evaluación	43
5	Resultados	43
5.1	Comparación global de arquitecturas	43
5.1.1	Métricas clave en FW	44
5.1.2	Comparación de rendimiento por tamaño de arbusto	44
5.1.3	Relación entre precisión individual y fidelidad espacial	45
5.1.4	Comparación global mediante radar de métricas	46
5.1.5	Matriz de resumen normalizado	46
5.1.6	Síntesis: ranking de modelos	47
5.2	Resultados detallados por arquitectura	47
5.2.1	Mask R-CNN	48
5.2.2	DeepLabV3+	50
5.2.3	PointRend-Instancias	52
5.2.4	PointRend-Semántico	54
5.2.5	Panoptic FPN	56
5.3	Comparación entre PI y FW	58
5.4	Efecto del umbral de puntuación y del posprocesado	59
5.5	Análisis cualitativo de las predicciones	60
5.5.1	Ejemplificación de predicciones en PI y FW	60
5.5.2	Tipología de errores	65
5.5.3	Síntesis cualitativa: fortalezas y debilidades	67
5.6	Interpretación ecológica de los resultados	68
5.7	Limitaciones del estudio	69
6	Conclusiones	70
7	Anexos	72
A	Otras tablas con métricas representativas	72
B	Otros gráficos representativos	75
	Referencias	77

1 Introducción

1.1 Contexto ecológico y ambiental

Los ecosistemas de alta montaña constituyen uno de los hábitats más sensibles ante el cambio climático, debido a que las especies que habitan en ellos están adaptadas a unas condiciones climáticas extremas, a un corto período de crecimiento, a suelos poco desarrollados y a una estacionalidad marcada [1]. Por tanto, en este contexto las especies arbustivas de alta montaña desempeñan una labor ecológica fundamental, ya que estas estabilizan suelos, mitigan la erosión de pendientes, retienen y almacenan agua en el sustrato edáfico, proporcionan recursos y refugio para la fauna y contribuyen al almacenamiento de carbono en zonas donde la cobertura forestal es limitada o incluso inexistente [2, 3].

En concreto, especies del género *Juniperus*, las cuales pueden manifestarse como arbustos o matorrales en alta montaña, presentan ciertas adaptaciones morfológicas y ecológicas significativas; suelen tolerar bajas temperaturas, escasez de la capa edáfica, alta exposición al viento y una vegetación escasa alrededor [4]. Esta combinación de factores hace que su detección, además de su cartografía y seguimiento temporal sean cruciales para, así, poder comprender la dinámica de los ecosistemas de alta montaña.

Debido al calentamiento global, en las últimas décadas se ha documentado una tendencia generalizada a desplazamientos altitudinales hacia cotas más elevadas en especies de montaña, lo que conlleva una contracción del hábitat adecuado y un aumento de la vulnerabilidad de aquellas especies que no pueden migrar o adaptarse lo suficientemente rápido [5, 6, 7]. Estas dinámicas alteran la distribución de los individuos y la estructura de la comunidad vegetal, las funciones del ecosistema y los servicios que dichos ecosistemas prestan [8].

De esta manera, el efecto combinado de la subida de temperatura y la insuficiente precipitación, provoca una notable redistribución de la regeneración en cotas elevadas, tanto para *Juniperus* como para el resto de especies arbustivas de montaña. Esto impide que los nuevos individuos se establezcan conforme se elevan los límites del matorral [9], lo que evidencia que no basta con el simple desplazamiento altitudinal, sino que la calidad del hábitat remanente y la capacidad de establecimiento se convierten en factores clave que limitan la respuesta de la vegetación al cambio climático.

Por otra parte, los arbustos de alta montaña suelen presentar gran variabilidad morfológica con respecto al tamaño, forma, densidad y distribución espacial, lo que se define como polimorfismo. Esto añade complejidad al monitoreo y la detección remota de individuos o grupos de estos arbustos. Sin embargo, en el estudio base de Khaldi et al. (2024) [10] se pone de manifiesto la importancia de monitorizar el tamaño y la distribución de arbustos longevos y de gran tamaño para evaluar los impactos a largo plazo del cambio climático en los ecosistemas de alta montaña. Por ello, es imprescindible el uso de técnicas de visión por computador (*computer vision*) que consideren no sólo la presencia o ausencia, sino la individualización, segmentación y cuantificación de los arbustos.

La variabilidad espacial y altitudinal, así como las condiciones topográficas (pendientes, orientación, sombras, capas de nieve residuales) en ambientes de alta montaña, generan desafíos específicos para la detección remota; las imágenes aéreas o satelitales pueden presentar sombras pronunciadas, distorsiones por pendiente, diferentes reflectancias según orientación y una cobertura vegetal muy heterogénea. Estos factores técnicos requieren de una combinación de conocimiento ecológico, preprocesamiento de imágenes y algoritmos de segmentación robustos.

En términos generales, este escenario ecológico-ambiental define una urgente necesidad metodológica; resulta esencial disponer de técnicas que permitan mapear con precisión los arbustos polimorfos de alta montaña, seguir su evolución en el tiempo y detectar sus desplazamientos altitudinales o contracciones de población. Por consiguiente, el presente trabajo se sitúa en el cruce entre ecología, teledetección y visión por computador, con la intención de aportar conocimiento sobre la distribución de especies de arbustos polimorfos en imágenes satelitales y los sesgos asociados a su detección mediante modelos de segmentación profunda.

1.2 Motivación y relevancia del estudio

En los últimos años, se ha observado una creciente incorporación de técnicas de aprendizaje profundo (*deep learning*) y teledetección en estudios ecológicos, lo que demuestra una considerable transformación en la manera de mapear, monitorizar e incluso comprender la vegetación en ambientes complejos, como son los ecosistemas de alta montaña. No obstante, los estudios referentes a la detección individualizada de arbustos, en específico, las especies arbustivas polimorfas en zona montañosas, siguen siendo relativamente escasos, por lo que hay una oportunidad metodológica y científica que el presente trabajo pretende abordar.

De esta manera, una de las motivaciones de este proyecto es la escasez de investigaciones especializadas que combinen la segmentación precisa de arbustos, su detección individualizada y el análisis de sesgos de modelos en estas condiciones. A diferencia de los trabajos sobre detección de vegetación que muestran que los modelos de segmentación semántica como DeepLabV3+ alcanzan un buen rendimiento en imágenes satelitales [11] y revisiones recientes que confirman que el *deep learning* es cada vez más utilizado en teledetección para vegetación [12], los estudios que se centran en ambientes montañosos, arbustos polimorfos y modelos de instancia o panópticos son muy limitados. El artículo de Khaldi et al. (2024) [10], y del que parte este TFM, muestra la viabilidad de un enfoque de segmentación de instancias en dicho contexto, pero a su vez evidencia limitaciones y abre la puerta a comparativas entre arquitecturas más diversas.

La segunda motivación principal es la gran relevancia ecológica y de conservación de este estudio. Como ya se ha mencionado previamente, las especies arbustivas de alta montaña presentan funciones imprescindibles en estos ecosistemas, puesto que estabilizan suelos, almacenan carbono, proveen de hábitat a diferentes especies animales y presentan una alta resiliencia ecológica frente al calentamiento global. Por consiguiente, es esencial disponer de metodologías capaces de cuantificar de forma precisa, a nivel de instancia o de cohorte, de su distribución, tamaño, densidad y cambios temporales, ya que resulta una significativa aportación tanto a la ciencia ecológica como a la gestión y conservación del territorio. Este planteamiento refuerza la importancia de desarrollar y validar modelos automáticos de detección que puedan apoyar la toma de decisiones en conservación de ecosistemas montañosos y el seguimiento de procesos dinámicos en condiciones ambientales extremas.

Por otro lado, también hay factores metodológicos-computacionales que motivan este proyecto. Primeramente, los modelos de clasificación y segmentación de vegetación más tradicionales (como índices de vegetación tipo NDVI) presentan claras limitaciones en entornos heterogéneos y de gran variabilidad morfológica, como es el caso de los arbustos polimorfos en ambientes montañosos. Así, estudios que tratan la detección de vegetación han demostrado que los modelos de *deep learning* superan a los enfoques convencionales en entornos de alta resolución [11]. En segundo lugar, existe una creciente disponi-

bilidad de arquitecturas de visión por computador accesibles a través de librerías como Detectron2 [13] y su capacidad para segmentación de instancias, semántica y panóptica, lo que permite plantear un análisis comparativo riguroso entre ellas. Por último, la identificación de sesgos inherentes al modelo (tamaño de arbusto, altitud, textura, pendiente, orientación, variabilidad fenológica) es aún una línea emergente en la literatura, por lo que su explotación puede aportar innovaciones metodológicas relevantes al estudio.

Desde la perspectiva aplicada, este trabajo se justifica porque permite generar una base de referencia para estudios futuros en otros ámbitos de vegetación de montaña y arrojar recomendaciones metodológicas claras para seleccionar la arquitectura de segmentación más adecuada, en función de las condiciones ecológicas, topográficas y de sensor. En este sentido, al comparar cuatro modelos (Mask R-CNN, DeepLabV3+, PointRend y PanopticFPN) en un escenario real de alta montaña y especies polimorfas, se aspira a ofrecer no sólo un ranking de desempeño, sino una reflexión sobre cómo y por qué un modelo puede superar a otro, y qué implicaciones tiene esto para investigadores, gestores de territorio y tecnologías de teledetección operativas.

En términos generales, la motivación y relevancia de este proyecto radican en su carácter interdisciplinar (ecológico, teledetección, visión por computador) y en su potencial para avanzar en la cuantificación precisa de procesos ecológicos en ambientes críticos, fomentar la reproducibilidad del análisis y orientar la aplicación práctica de modelos de segmentación automatizados en ámbitos de conservación. Por lo tanto, este trabajo se posiciona como una contribución estratégica tanto al conocimiento científico como a la gestión aplicada de ecosistemas de alta montaña.

1.3 Problemática de la detección de especies polimorfas

La detección individualizada de especies arbustivas en ecosistemas de alta montaña conlleva una combinación de retos ecológicos, de sensor y de modelado que aparecen atenuados en contextos más homogéneos. Por ejemplo, especies como *Juniperus communis* y *Juniperus sabina* poseen una gran variabilidad en su forma (hemiesférica, en bandas, en arcos), su tamaño (de XS a XXL), su densidad (de individuos aislados a colonias coalescentes), su coloración (verdes a rojizos o marrones) y su densidad de follaje, lo que provoca patrones visuales muy diversos y, con frecuencia, ambiguos para algoritmos de visión por computador entrenados con anotaciones humanas. Por ende, este carácter polimorfo causa una confusión mayor sobre fondos heterogéneos (bordes de lagunas, suelo húmedo, rocas oscuras), favoreciendo el solape de las copas y propiciando la fragmentación (*splits*) o la fusión (*merges*) de instancias durante la inferencia. Estos problemas penalizan considerablemente a los detectores cuando son evaluados con métricas muy estrictas como IoU [14].

Limitaciones de resolución y geometría de adquisición

Uno de los factores que condiciona la capacidad de discernir copas pequeñas o fragmentadas es la resolución espacial, puesto que, con píxeles de tamaño decimétrico, las copas de tamaño XS y S tienden a confundirse con texturas del suelo o con herbáceas [15]. Adicionalmente, la pendiente, la orientación y las sombras presentes en ecosistemas de alta montaña añaden variaciones de iluminación y proyección que difuminan bordes y generan oclusiones, lo que afecta tanto a algoritmos basados en contorno (*edge-aware*) como a U-Nets multiescala [16]. Estos factores se amplifican ante grandes copas de arbustos (tamaños XL y XXL), ya que el modelo puede no detectar todo el objeto dentro de la tesela (*tile*) y confundirlo con oscuras praderas o grandes masas de agua.

Limitaciones espectrales y estacionales

Trabajar únicamente con imágenes RGB limita notoriamente la separabilidad espectral frente a aguas oscuras, rocas húmedas o herbáceas. En contraposición, bandas NIR o Red-Edge mejorarían la discriminación fisiológica de *Juniperus*, pero no siempre están disponibles a la resolución deseada. Asimismo, variaciones temporales como presencia de nieve, humedad en el suelo o la propia fenología y ángulos de visión distintos entre mosaicos, introducen cambios de dominio que degradan la generalización si no se controlan o modelan adecuadamente.

Ambigüedad de anotación y ground truth incierto

En arbustos polimorfos, puede existir cierta incertidumbre a la hora de etiquetar a los individuos, ya que, por ejemplo, dos expertos pueden discrepar acerca de si un parche continuo es un individuo o varios, lo que penaliza al modelo bajo IoU clásico (emparejamiento 1-a-1 de instancias) y llevan a falsos positivos (troneras de roquedo, que son pequeñas grietas naturales en formaciones rocosas) o falsos negativos (colonias coalescentes, copas muy grandes o ralas). Para abordar esta problemática, Khaldi et al. [10] propusieron una nueva métrica, S-IoU (*Soft IoU*), la que evalúa la proporción de área de la etiqueta cubierta por todas las predicciones coincidentes y, simétricamente, la proporción de área de la predicción cubierta por todas las etiquetas coincidentes, mitigando así la penalización por splits/merges inevitables en especies polimorfas. En este estudio, la nueva métrica generada conseguía un aumento de F1 con respecto a IoU en los dos conjuntos de datos utilizados, evidenciando de este modo que parte del error era atribuible a la ambigüedad ontológica del objeto más que a fallos del propio detector.

Sesgos por tamaño y altitud, dominio PI → FW

Los resultados arrojados muestran un decrecimiento en el rendimiento del modelo en los tamaños más pequeños (XS y S), mejorando significativamente en los tamaños más grandes (L–XXL). De la misma manera, existe un gradiente altitudinal, ya que los arbustos más pequeños se encuentran en cotas más altas, mientras que los más grandes se localizan en zonas más bajas, lo que interactúa con la capacidad de detección [10]. A esto se le añade un cambio de dominio entre dos conjuntos de datos; PI (anotaciones por fotointerpretación, abundante pero menos precisa) y FW (anotaciones por trabajo de campo, menos abundante, pero de mayor calidad), que reduce F1 en la evaluación externa; este patrón es coherente con la literatura de vegetación dispersa: la fusión de enfoques (OBIA + Mask R-CNN) y el control espacial de la validación mejoran robustez y evitan sobreajuste espacial.

Elección del paradigma de segmentación (instancia, semántica, panóptica)

En vegetación polimorfa y dispersa, la segmentación de instancias (como Mask R-CNN) facilita el cómputo de métricas ecológicas por individuo (tamaño de copa, densidad), pero es sensible a splits/merges y al “NMS” en objetos contiguos. Por otra parte, la segmentación semántica (por ejemplo, DeepLabV3+) tiende a suavizar y mapear masas de matorral, perdiendo identidad individual en colonias coalescentes; en cambio, panóptica (como PanopticFPN) busca conciliar ambos mundos, aunque en vegetación densa su rendimiento depende de la calidad del thing/stuff split y de la coherencia de instancias adyacentes. Adicionalmente, el sesgo del paradigma elegido es parte del problema, ya que cada arquitectura aporta ventajas y compromisos diferentes en especies polimorfas.

Implicación práctica

En este tipo de especies, el error geométrico (borde imperfecto, leve fuga o *leakage*) puede ser menos relevante para objetivos de cobertura y densidad que el error ontológico (contar 1 vs. 2 individuos). De ahí que métricas más flexibles como S-IoU, validaciones por tamaño y análisis por gradiente altitudinal sean imprescindibles para interpretar el rendimiento más allá del IoU convencional.

En definitiva, la complejidad recae menos en la detección bruta de los arbustos y más en definir y evaluar correctamente qué cuenta como un individuo bajo gran variabilidad morfológica y condiciones topográficas y ópticas cambiantes. Este matiz metodológico explica por qué la evaluación y la selección de arquitectura deben alinearse con el objetivo ecológico (individuo vs. masa; conteo vs. cobertura) y por qué el análisis de sesgos por tamaño, altitud y dominio es central en especies polimorfas como los *Juniperus*.

1.4 Estado actual de la teledetección y la visión por computador en ecología

La combinación de la teledetección y la visión por computador ha transformado considerablemente los métodos con los que se aborda el monitoreo, mapeo y el análisis de la vegetación en entornos naturales. La detección tradicional se basaba en índices espectrales (como el Índice de vegetación de diferencia normalizada, NDVI) y en clasificaciones de cobertura vegetal a gran escala; no obstante, en esta última década se ha apreciado un gran avance hacia la segmentación automatizada, la detección de objetos de manera individual y el uso de deep learning para captar patrones complejos en imágenes aéreas o satelitales.

Un ejemplo del uso de imágenes de teledetección para el mapeo de vegetación es el artículo realizado por Xie en 2008 [17], donde se pone de relieve las ventajas de la utilización de sensores multispectrales y las limitaciones en resolución espacial y temporal. Actualmente, las revisiones más recientes concurren en la creciente adopción de arquitecturas de aprendizaje automático (*machine learning*) y deep learning para la identificación de especies vegetales, el seguimiento de fenología, la estimación de biomasa y la clasificación operativa de comunidades vegetales [18].

1.4.1 Evolución de los métodos de teledetección en ecología

La detección automática ha evolucionado desde la mera utilización de índices espectrales hacia plataformas multiescala (satélite, avión, UAV) y sensores diversos (óptico, multispectral, hiperespectral, LiDAR, radar). Por ejemplo, la reciente revisión de Matyukira de 2024 [19] documenta cómo el mapeo de vegetación se ha beneficiado del aumento de la resolución espacial, la disponibilidad de datos de alta frecuencia y la integración de machine learning. Del mismo modo, Givnish (2024) [20] analiza cómo los modelos de deep learning han permitido pasar del mapeo de cobertura a la predicción de la presencia de especies raras y de estratos subyacentes, a escalas que van de metros a cientos de kilómetros.

Todo este avance ha permitido que los ecólogos puedan abandonar en muchos casos los esfuerzos exclusivamente centrados en parcelas terrestres y aprovechar *big data* de teledetección y visión por computador.

1.4.2 Aplicación de la visión por computador y el deep learning

En el campo de la visión por computador aplicada a ecosistemas vegetales, la focalización ha pasado de la clasificación de cobertura a la segmentación de instancias, conteo

individualizado, estimación de tamaño de copa, densidad y otros parámetros ecológicos finos. Esta transición es trascendental para tareas como la que plantea este proyecto, la detección individualizada de arbustos polimorfos en alta montaña. Por ejemplo, el estudio de Chang et al. (2025) [21] sobre UAVs revisa 79 trabajos y observa que los sensores RGB dominan, aunque persisten retos de resolución, adquisición y procesamiento para vegetación no homogénea. En otro análisis global, Yan et al. (2025) [22] sitúan la teledetección basada en machine learning como la tendencia dominante para el monitoreo de biodiversidad a escala continental.

1.4.3 Oportunidades y desafíos

El uso de deep learning y visión por computador aporta oportunidades fundamentales, las cuales son:

- Una mayor exactitud y automatización. Los modelos son capaces de aprender patrones complejos de textura, forma y contexto espacial que los índices tradicionales no captan.
- La escalabilidad espacial y temporal. Es posible procesar ortomosaicos extensos o series temporales para detectar cambios dinámicos.
- La individualización de objetos vegetales. En lugar de mapear masas de vegetación, se puede extraer información por individuo (área de copa, densidad, etc.), lo que es crucial para especies polimorfas y dispersas.

En contraposición, también presenta retos persistentes:

- Un desbalance de datos y clasificación sesgada. Los entornos naturales presentan gran variabilidad y rareza de ciertas clases, lo que afecta negativamente al entrenamiento.
- Un cambio de dominio y generalización. Los modelos entrenados en un área o sensor pueden perder rendimiento en otras zonas.
- Resolución espacial o temporal frente a coste y disponibilidad. Sensores de altísima resolución no siempre están disponibles o son costosos; además, las plataformas (UAV, satélites) tienen limitaciones de cobertura o frecuencia.
- Interpretabilidad y sesgos del modelo. Los modelos de visión por computador pueden reproducir sesgos en la detección de tamaños, formas o condiciones ambientales, y estos sesgos deben identificarse, cuantificarse y gestionarse.
- Integración ecológica. No basta con segmentar vegetación, sino que, además, el resultado debe interpretarse en clave ecológica (por ejemplo, tamaño del individuo, densidad poblacional, directrices de conservación) y esto introduce una capa de complejidad metodológica adicional.

1.4.4 Relevancia para el presente estudio

Teniendo en cuenta tanto la evolución como los desafíos descritos, el presente trabajo se inserta en un punto especialmente favorable de la investigación: la detección de especies arbustivas individuales en ambientes de alta montaña, mediante modelos de visión por computador de última generación. La revisión del estado del arte indica que, aunque la

tecnología está madura en ámbitos más homogéneos (bosques, cultivos, praderas), aún existe un nicho relevante y científicamente útil para trabajos que aborden vegetación polimorfa dispersa, en condiciones topográficas complicadas y con modelos comparativos. La combinación del análisis ecológico, los datos de alta resolución, e implementación de varios modelos (instancia, semántica y panóptica) permite aportar tanto al ámbito ecológico como al de visión por computador metodológica.

1.5 Objetivos generales y específicos del TFM

El presente Trabajo Fin de Máster se sitúa en la intersección entre la teledetección ecológica y la visión por computador, teniendo como principal objetivo la optimización de la detección individual de matorrales del género *Juniperus* en ecosistemas de alta montaña, utilizando para ello técnicas avanzadas de segmentación profunda. En concreto, el estudio se centra en dos especies dominantes en Sierra Nevada (*Juniperus communis* y *Juniperus sabina*), cuya distribución y dinámica están estrechamente ligadas a procesos de cambio climático y a transformaciones en la estructura del paisaje.

Este TFM se apoya en el marco metodológico introducido por Khaldi et al. (2024) [10], donde se emplea el modelo Mask R-CNN para la segmentación de instancias. Por tanto, este trabajo pretende ampliar y complementar dicho enfoque mediante la comparación sistemática de arquitecturas pertenecientes a distintos paradigmas de segmentación profunda: instancia, semántica y panóptica. La evaluación se realiza utilizando dos conjuntos de datos independientes: *Photo Interpretation Data* (PI), empleado para entrenamiento y validación interna, y *Field Work Data* (FW), considerado como evaluación externa y, por ello, como medida realista de la capacidad de generalización de los modelos.

De esta manera, el objetivo general de este TFM es evaluar comparativamente el rendimiento y la capacidad de generalización de diferentes arquitecturas de segmentación profunda para la detección individual de matorrales de *Juniperus* en imágenes satelitales de alta resolución, con el fin de determinar la arquitectura más adecuada y comprender los factores que explican sus diferencias de comportamiento.

A partir de este objetivo general, se establecen los siguientes objetivos específicos:

1. Reproducir y validar el enfoque base de Mask R-CNN propuesto por Khaldi et al. (2024) [10] utilizando los conjuntos PI y FW, garantizando coherencia metodológica y estableciendo un punto de referencia sólido. Este objetivo recoge la naturaleza complementaria del trabajo respecto al desarrollo previo realizado por Khaldi et al. (2024) [10].
2. Implementar y entrenar arquitecturas alternativas de segmentación, incluyendo segmentación semántica (DeepLabV3+), segmentación de frontera adaptativa (PointRend) y segmentación panóptica (Panoptic FPN), manteniendo configuraciones homogéneas de datos, anotaciones y parámetros de entrenamiento.
3. Evaluar comparativamente el rendimiento de todas las arquitecturas mediante métricas propias de visión por computador: F1 basado en S-IoU, IoU, mIoU, precisión, recall y métricas por clase de tamaño (XS-XXL).
4. Analizar la capacidad de generalización de los modelos entre dominios, comparando el rendimiento en PI (in-domain) y FW (out-of-domain), e identificando patrones de degradación, sensibilidad al umbral de puntuación y sesgos asociados al cambio de contexto.

5. Cuantificar el impacto ecológico de las predicciones mediante métricas derivadas relevantes para la gestión del matorral, como cobertura de copa, densidad de individuos y coeficiente de determinación (R^2), evaluando la utilidad real de los modelos en aplicaciones ecológicas.
6. Caracterizar los sesgos de detección asociados a cada arquitectura, incluyendo la dependencia con el tamaño del arbusto (XS–XXL), la aparición de errores sistemáticos (fusión, fragmentación, omisión), los efectos del posprocesado (*watershed*) y la influencia de la estructura y textura del paisaje.
7. Proponer recomendaciones metodológicas para futuros estudios de teledetección ecológica, incluyendo sugerencias de modelos, configuraciones de entrenamiento y posibles líneas de mejora (técnicas de *data augmentation*, *backbones* avanzados o integración de información multiespectral).

En definitiva, estos objetivos buscan no sólo determinar qué arquitectura alcanza el mejor rendimiento cuantitativo, sino también comprender por qué lo hace y cómo los sesgos de detección influyen en la interpretación ecológica de los resultados, proporcionando así una base sólida para el uso de segmentación profunda en la monitorización y gestión de ecosistemas de alta montaña.

1.6 Estructura del documento

El presente trabajo se organiza en seis capítulos principales, complementados por los apartados de referencias bibliográficas y anexos, siguiendo una estructura lógica que abarca desde el contexto teórico hasta la discusión e interpretación de los resultados:

- Capítulo 1: Introducción. Presenta el contexto ecológico y ambiental del estudio, la problemática de la detección de especies polimorfas, el estado actual de la teledetección y la visión por computador en ecología, así como los objetivos y la estructura del trabajo.
- Capítulo 2: Marco bibliográfico. Reúne los principales antecedentes científicos relacionados con la teledetección de vegetación, los modelos de segmentación utilizados en visión por computador y los trabajos previos aplicados a especies arbustivas de alta montaña.
- Capítulo 3: Área de estudio y datos. Describe la localización geográfica (Sierra Nevada), las especies analizadas (*Juniperus communis* y *J. sabina*), las fuentes de datos satelitales, las características del conjunto de datos *JuniperMapper: AI for Shrub Delineation* (división PI y FW) [23], y el proceso de anotación y preprocesamiento.
- Capítulo 4: Metodología. Detalla el flujo de trabajo desarrollado, las arquitecturas evaluadas (Mask R-CNN, DeepLabV3+, PointRend y PanopticFPN), los parámetros de entrenamiento, las métricas de evaluación y el enfoque de análisis de sesgos.
- Capítulo 5: Resultados. Presenta los resultados obtenidos para cada modelo, con comparaciones cuantitativas y cualitativas, análisis de errores, visualización de máscaras y evaluación de los sesgos asociados a la detección. Además, se realiza la interpretación de los resultados en clave ecológica y metodológica, analizando las diferencias entre modelos, los efectos de los sesgos detectados y su relación con la dinámica altitudinal de las especies de *Juniperus*.

- Capítulo 6: Conclusiones y líneas futuras. Resume los hallazgos principales, identifica el modelo con mejor desempeño y sugiere posibles líneas de investigación futura, tanto en el ámbito ecológico como en el computacional.

Finalmente, se incluyen las referencias bibliográficas empleadas a lo largo del trabajo (formato APA) y los anexos, donde se presentan tablas y figuras adicionales para comprender mejor cómo predicen los modelos analizados.

2 Marco bibliográfico

2.1 Introducción al deep learning en teledetección

En las dos últimas décadas, la teledetección ha experimentado una transformación radical de su metodología gracias a la incorporación de técnicas de deep learning. En un principio, se utilizaban métodos estadísticos clásicos o algoritmos de machine learning supervisados como *Random Forest*, *k-Nearest Neighbors (k-NN)* o *Support Vector Machines (SVM)* para la clasificación de vegetación y la cobertura del suelo, pero estos mecanismos dependían fuertemente de descriptores manuales e índices espectrales (NDVI, EVI, SAVI) [24, 25].

Por el contrario, y debido al auge de las redes neuronales convolucionales (CNN) a partir de 2012 [26], la teledetección adoptó rápidamente estos modelos, los cuales permitían aprender jerarquías de características visuales de manera directa a partir de los datos sin requerir ingeniería manual de variables. En el caso concreto de la teledetección vegetal, este salto permitió pasar de la mera clasificación de píxeles a la detección y segmentación de objetos individuales (como árboles, arbustos, cultivos o parches de vegetación) incluso en ambientes complejos como bosques heterogéneos o ecosistemas alpinos [14, 15].

Gracias al desarrollo de arquitecturas profundas especializadas se ha podido cubrir diferentes niveles de análisis espacial:

- Clasificación de escenas (*scene classification*): se asigna una etiqueta global a una imagen o escena.
- Detección de objetos: se localiza y clasifica objetos individuales mediante cajas delimitadoras (*bounding boxes*).
- Segmentación semántica: se asigna una clase a cada píxel, sin distinguir instancias individuales.
- Segmentación de instancias: se diferencia píxel a píxel cada objeto, incluso si pertenecen a la misma clase.
- Segmentación panóptica: se combina las dos segmentaciones anteriores, ofreciendo así una visión unificada de objetos (*things*) y sustancias (*stuff*) [27].

Dentro del contexto de la teledetección ecológica, el nivel más relevante es el de la segmentación, ya que permite cuantificar entidades biológicas discretas (individuos, copas, arbustos) y derivar métricas ecológicas como densidad, cobertura o tamaño de copa. Por ello, el presente trabajo se centra en la comparación de modelos de segmentación profunda desarrollados entre 2017 y 2020, cuya evolución refleja la progresiva especialización de la visión por computador hacia tareas de alta precisión, contextualización y coherencia espacial.

2.2 Evolución cronológica de los modelos de segmentación profunda

A continuación, se ilustra la evolución cronológica de los modelos utilizados en este TFM, atendiendo a la madurez tecnológica de la visión por computador: Mask R-CNN, DeepLabV3+, Panoptic FPN y PointRend. Cada una de estas arquitecturas ha surgido con el fin de superar las limitaciones de las anteriores, incorporando diferentes aspectos como la precisión, el contexto multiescala o el refinamiento de bordes.

De esta manera, se detalla en las siguientes líneas su secuencia temporal y conceptual:

2017 – Mask R-CNN: segmentación de instancias de precisión

El modelo Mask R-CNN [28] marcó un punto de inflexión, debido a la extensión que se produjo de la arquitectura Faster R-CNN [29], añadiendo a la base una rama adicional de segmentación. A diferencia de Faster R-CNN, que realiza la detección de objetos mediante bounding boxes, el modelo Mask R-CNN añade una rama de máscara binaria que predice, para cada región propuesta, una máscara a nivel de píxel.

Por lo tanto, la arquitectura interna de Mask R-CNN consta de tres componentes principales:

1. Red troncal (backbone), habitualmente ResNet-50 o ResNet-101 con *Feature Pyramid Network (FPN)*, para poder capturar características multiescala.
2. *Region Proposal Network (RPN)*, que genera regiones candidatas donde podrían existir objetos.
3. Ramas paralelas, una para clasificación, otra para regresión de bounding box y una tercera (la nueva rama añadida) para generar la máscara de segmentación.

Con el uso de Mask R-CNN se popularizó la segmentación de instancias y, con él, se obtuvo una gran precisión en bases de datos de referencia como COCO¹ [30]. En ecología, ha sido aplicado con éxito a la detección individual de árboles y arbustos [10, 14]. No obstante, también presenta limitaciones, ya que, al basarse en regiones independientes, este modelo tiende a fragmentar u omitir objetos parcialmente solapados, como ocurre en especies polimorfas con copas contiguas.

2018–2019 – DeepLab V3+: segmentación semántica multiescala

El modelo DeepLabV3+ [31] supuso un salto cualitativo en la segmentación semántica, ya que introdujo dos innovaciones clave:

1. El uso de convoluciones dilatadas (*atrous*) para capturar contexto espacial sin perder resolución.
2. El módulo *Atrous Spatial Pyramid Pooling (ASPP)*, que combina filtros de varios tamaños de dilatación con el objetivo de integrar información a múltiples escalas.

Además, este nuevo modelo incorporó un decodificador ligero que refina bordes y transiciones de clase, mejorando así la definición de los límites de los objetos frente a sus predecesores (DeepLabV2/V3).

¹COCO (Common Objects in Context) es un conjunto de datos ampliamente usado en visión por computador, que incluye imágenes con objetos cotidianos anotados para tareas de detección y segmentación.

DeepLabV3+ se consolidó como referencia en segmentación semántica, siendo entrenado con bases de datos como Cityscapes² [32]. Se ha demostrado además que esta arquitectura es especialmente eficaz cuando el objetivo es mapear categorías continuas o extensas (masa de vegetación, suelo, roca) sin distinguir instancias individuales. Por ello, en el contexto de vegetación de montaña, es útil para mapear coberturas y estimar áreas continuas, aunque no proporciona directamente conteo o métricas individuales de los arbustos detectados.

2020 – PointRend: refinamiento adaptativo de bordes

El modelo PointRend (*Point-based Rendering for Image Segmentation*) fue propuesto por Kirillov et al. (2020) [33] como una extensión compatible con Mask R-CNN o DeepLab. Su objetivo, por tanto, era resolver un problema recurrente: refinar los bordes irregulares o poco definidos que aparecen en las máscaras creadas por las CNN.

De esta manera, PointRend aplica un mecanismo de renderizado progresivo basado en puntos, que refina las regiones de incertidumbre de la máscara (generalmente en bordes). PointRend es capaz de seleccionar dinámicamente los puntos con mayor incertidumbre o ambigüedad y los evalúa aplicando un decodificador MLP de alta resolución, en lugar de procesar la imagen entera a la misma resolución, como hacían los otros modelos.

Esta mejora permite generar máscaras suaves y precisas en límites complejos, como copas de arbustos, coronas de árboles o vegetación dispersa. Además, debido a su capacidad para preservar detalles finos sin un gran coste computacional, aplicar PointRend en ecosistemas polimorfos resulta especialmente prometedor, ya que la textura y los contornos son complejos y críticos.

2019–2020 – Panoptic FPN: visión unificada del paisaje

El modelo Panoptic Feature Pyramid Network (Panoptic FPN) [27] ha sido desarrollado por el mismo grupo de investigación que el modelo PointRend. Su propósito ha sido integrar, en una única arquitectura, las dos visiones complementarias de la segmentación; por un lado, la segmentación de instancias, que detecta objetos individuales (things) y, por otro, la segmentación semántica, que detecta clases continuas o fondos (stuff).

Como se ha mencionado, Panoptic FPN combina ambas técnicas mediante una arquitectura FPN compartida y una fusión panóptica que asigna a cada píxel una etiqueta única, resolviendo conflictos entre predicciones de instancias y de fondo. Esta arquitectura ha dado origen al concepto de segmentación panóptica, que busca ofrecer una representación completa del entorno (objetos + contexto).

En ecología y teledetección, esta aproximación es particularmente interesante porque permite cuantificar tanto individuos discretos (arbustos, árboles) como superficies continuas (suelo, roca, hierba) en una misma imagen, favoreciendo análisis más integrales del paisaje [34].

Tras estas descripciones, se muestra en la Tabla 1 una comparativa esquemática de las cuatro arquitecturas.

²Cityscapes es un conjunto de datos centrado en escenas urbanas, diseñado para tareas de segmentación semántica y reconocimiento de escenas de conducción. Incluye imágenes tomadas desde un vehículo en diversas ciudades europeas.

Modelo	Año	Segmentación	Innovaciones	Limitaciones
Mask R-CNN	2017	Instancias	Rama de máscara por píxel; precisión individual	Dificultad con solapes y fragmentaciones
DeepLabV3+	2018-2019	Semántica	ASPP y convoluciones dilatadas; decodificador de bordes	No distingue individuos
PointRend	2020	Instancia/Semántica	Refinamiento de bordes adaptativo	Dependiente del modelo base
Panoptic FPN	2019-2020	Panóptica	Integración instancias + fondos; coherencia global	Alta demanda computacional; tuning complejo

Tabla 1: Resumen de los cuatro modelos de segmentación profunda estudiados en este trabajo, incluyendo fecha de desarrollo, tipo de segmentación, principales innovaciones y limitaciones.

Esta evolución permite observar cómo los modelos han pasado de la detección individual precisa (Mask R-CNN) hacia una representación contextual y multiescala del paisaje (Panoptic FPN), incorporando además un refinamiento intermedio (DeepLabV3+ y PointRend) que responden a diversas necesidades concretas de precisión o continuidad espacial. Por lo tanto, la comparación de estas arquitecturas bajo un mismo conjunto de datos (como se hace en este TFM) permite analizar de manera rigurosa cómo el paradigma de segmentación elegido condiciona los resultados ecológicos y qué sesgos emergen de cada aproximación.

2.3 Aplicaciones de los modelos de segmentación en teledetección y ecología

El uso de arquitecturas de segmentación profunda en el ámbito de la teledetección ecológica ha conseguido grandes avances en el análisis de la vegetación, pasando de una simple clasificación de cobertura a la detección y, además, cuantificación individual de las especies vegetales. Esta nueva habilidad resulta especialmente útil para el estudio de la estructura, la dinámica y la respuesta de los ecosistemas a factores como el calentamiento global o las perturbaciones antrópicas.

Por ello, estas arquitecturas de segmentación (tanto de instancias como semánticas o panópticas) se han aplicado a una gran gama de contextos ecológicos, como pueden ser el monitoreo forestal, la identificación de especies invasoras, la estimación de biomasa, la detección de cultivos o el mapeo de vegetación en alta montaña. De esta manera, se reflejan en los siguientes apartados una síntesis de las principales aplicaciones agrupadas por modelo.

2.3.1 Mask R-CNN: teledetección y ecología

Mask R-CNN ha sido el modelo más ampliamente utilizado en teledetección vegetal debido a su gran capacidad para distinguir objetos individuales y proporcionar métricas asociadas a cada instancia (área de copa, perímetro, altura). En contextos forestales, ha conseguido alcanzar una gran precisión en la detección de copas de árboles en imágenes de dron y satélite [35, 36]. Por otra parte, en ambientes áridos y semiáridos, Guirado et al. (2021) [14] combinaron este modelo con análisis de objetos basados en imagen (OBIA) para segmentar vegetación dispersa en sensores de muy alta resolución, logrando con ello mejoras notorias con respecto a métodos tradicionales.

En estudios más recientes, Khaldi et al. (2024) [10] aplicaron Mask R-CNN con el objetivo de detectar de manera individualizada arbustos polimorfos de alta montaña en Sierra Nevada, obteniendo, por un lado, resultados superiores en tamaños medianos y grandes, pero, por otro, mostrando sesgos de detección en arbustos pequeños (tamaños XS y S). Por tanto, este estudio puso de manifiesto tanto el gran potencial al igual que las limitaciones del enfoque de instancia en especies con gran variabilidad morfológica como ocurre con los *Juniperus*.

Adicionalmente, este modelo tiene otras aplicaciones, incluyendo la detección de especies invasoras mediante imágenes RGB o multiespectrales [37], el mapeo de cultivos y pastizales [38], y la monitorización de dinámica postincendio [39], lo que acentúa la versatilidad del modelo en entornos ecológicos variados.

2.3.2 DeepLabV3+: segmentación semántica en vegetación y coberturas

DeepLabV3+ es el modelo referente en segmentación semántica para imágenes de teledetección, ya que proporciona clasificaciones continuas a nivel de píxel que resultan idóneas para mapear coberturas vegetales extensas o tipos de suelo. Además, se ha aprovechado su capacidad multiescala basada en el módulo ASPP para mapear praderas, humedales, sabanas y bosques con alta precisión [40].

Dentro de la ecología vegetal, DeepLabV3+ se ha empleado en múltiples tareas, como la identificación de especies invasoras [18], la segmentación de plantaciones forestales y coberturas agrícolas [41] y la estimación de biomasa y salud del dosel utilizando para ello imágenes Sentinel-2 y WorldView-3 [42].

Aunque este modelo no distingue instancias individuales, su rendimiento superior en continuidad espacial lo convierte en un modelo óptimo cuando el principal interés es la cuantificación de la cobertura total o patrones de distribución, más que el conteo de individuos.

2.3.3 PointRend: refinamiento de bordes en ecosistemas complejos

El modelo PointRend se ha aplicado en problemas bajo condiciones de alta heterogeneidad o con límites vegetación-suelo difusos, donde las arquitecturas tradicionales pierden precisión de borde. De hecho, en estudios con UAV y ortomosaicos de vegetación natural, el modelo PointRend ha permitido una mejora de la definición de los contornos de copas arbóreas y arbustos [16], lo que es especialmente valioso en áreas montañosas, dunas o zonas semiáridas, ya que las sombras y las texturas del suelo suelen confundir a los modelos convencionales.

Gracias a su enfoque de renderizado progresivo, se genera un equilibrio entre resolución y coste computacional, resultando ser idóneo como complemento de refinamiento en flujos de trabajo basados en Mask R-CNN o DeepLabV3+. Dentro del contexto de la teledetección ecológica, su uso sigue siendo incipiente, pero existen estudios recientes que sugieren que PointRend puede aumentar considerablemente la precisión de los límites de la vegetación detectada [33].

2.3.4 Panoptic FPN: visión integral del paisaje

Panoptic FPN representa una de las propuestas de modelo más avanzadas de los últimos años, ya que combina tanto la segmentación de instancias como la segmentación semántica en una salida unificada. Por ello, esta característica lo convierte en un modelo notablemente atractivo para estudios ecológicos donde conviven elementos discretos

(arbustos o árboles) y clases continuas (suelo, roca, herbáceas), permitiendo así una descripción completa de todo el mosaico ecológico.

En detección automática, Panoptic FPN se ha utilizado con múltiples objetivos; como son la clasificación urbana y de paisaje heterogéneo, la detección de cultivos y otros objetos lineales en agricultura de precisión [34], y, más recientemente, en mapeo de vegetación costera y zonas áridas en las que la segmentación panóptica mejora la coherencia espacial frente a los enfoques separados [43].

Aunque este modelo conlleva una mayor demandad de entrenamiento y presenta una complejidad superior, Panoptic FPN ha resultado ser un avance hacia una visión ecológica más integral, combinando detección individual y contextualización espacial dentro del mismo marco.

2.3.5 Síntesis general

Como se ha desarrollado, se puede comprobar cómo la literatura evidencia cómo la aplicación de arquitecturas de segmentación profunda en teledetección ecológica se encuentra en rápida expansión.

De forma general, el modelo Mask R-CNN se ha consolidado como el modelo más utilizado para la detección individual mientras que DeepLabV3+ domina la cartografía semántica, el modelo PointRend emerge como herramienta de refinamiento complementando a los dos modelos anteriores, y Panoptic FPN propone una visión unificada del paisaje combinando ambos tipos de segmentaciones. Debido a estas diferencias, la comparación sistemática de estas arquitecturas, como la que se plantea en este TFM, resulta crucial para determinar qué paradigma produce resultados más útiles y menos sesgados en ecosistemas complejos como los de alta montaña, además del hecho de que esta comparativa es todavía escasa.

2.4 Comparativa crítica y limitaciones de los enfoques de segmentación en ecología

Esta revisión a la literatura más reciente pone de relieve que la aplicación de modelos de segmentación profunda a la teledetección ecológica ha supuesto un avance decisivo en la capacidad para mapear y cuantificar la vegetación. No obstante, los diferentes paradigmas (instancia, semántico y panóptico) presentan fortalezas y debilidades complementarias, las que condicionan tanto la precisión geométrica como la interpretación ecológica de los resultados.

En primer lugar, los modelos de segmentación de instancias, dentro de los cuales predomina Mask R-CNN [28], se han consolidado como el estándar para la detección individual de elementos vegetales discretos, como, por ejemplo, copas o arbustos [10, 14]. La principal ventaja de esta segmentación radica en la posibilidad de derivar métricas por objeto (área, perímetro, cobertura) útiles para estimar densidad o biomasa. En cambio, su enfoque basado en regiones propuestas usualmente produce errores de sobresegmentación o solapamiento, especialmente en especies polimorfas o densamente agregadas, donde la morfología irregular y la proximidad espacial de la vegetación dificultan la separación de las instancias [36, 37]. Esta limitación es particularmente relevante en ecosistemas de alta montaña, donde las copas de *Juniperus* pueden entrelazarse y generar falsas fusiones o divisiones.

En segundo lugar, los modelos de segmentación semántica como DeepLabV3+ [31, 41], sobresalen en la coherencia espacial y la continuidad de las coberturas. Estos modelos son capaces de representar patrones de distribución de vegetación o gradientes altitudinales con gran fidelidad, lo que resulta esencial para estudios de dinámica ecológica [44, 45].

Sin embargo, su limitación más destacable es la incapacidad para distinguir instancias individuales, lo que impide analizar procesos ecológicos dependientes del individuo, como competencia o mortalidad, reduciendo su utilidad a la hora de aportar información a escala de planta.

En tercer lugar, se sitúan arquitecturas híbridas como PointRend [33], que introducen un refinamiento de bordes adaptativo capaz de mejorar la definición de las máscaras sin aumentar el costo computacional. Aunque su aplicación en teledetección aún es limitada, los estudios disponibles muestran un incremento notable en la precisión de contornos [16, 46], lo que sugiere su potencial para aplicarlo en ecosistemas donde la textura o el relieve dificultan la segmentación clásica.

Por último, la segmentación panóptica, como la que se aplica en Panoptic FPN [27], representan un paso hacia la unificación semántica y de instancias. Este enfoque permite combinar objetos discretos (things) y fondos continuos (stuff) dentro de una misma predicción, logrando de este modo una representación más completa del paisaje [34, 43]. Sin embargo, su implementación requiere un considerable aumento del costo computacional y una mayor exigencia en el ajuste de hiperparámetros, además de no existir un consenso sobre cómo adaptar las métricas panópticas como *Panoptic Quality* (PQ) a contextos ecológicos donde predominan elementos biológicos de geometría irregular.

En líneas generales, se puede afirmar que ningún modelo satisface completamente las necesidades de la detección de especies polimorfas en ecosistemas naturales. Mientras Mask R-CNN proporciona un alto nivel de detalle individual pero sufre con las formas complejas, DeepLabV3+ ofrece mapas continuos pero pierde información de instancia, y Panoptic FPN plantea una solución combinada aún poco explorada pero más costosa en cuanto a su computación. Estas debilidades justifican la comparación planteada en este TFM, el cual busca identificar qué arquitectura consigue el mejor equilibrio entre precisión geométrica, coherencia ecológica y capacidad de generalización entre dominios de datos (Photo Interpretation Data y Field Work Data), teniendo en consideración además el costo computacional que el entrenamiento de cada arquitectura conlleva.

Además, este análisis comparativo permite evaluar los sesgos de detección inherentes a cada paradigma, aportando información relevante sobre cómo los modelos de computer vision interpretan la variabilidad morfológica de las especies y hasta qué punto estos sesgos pueden explotarse o corregirse en futuras investigaciones sobre teledetección de especies vegetales de alta montaña.

Un aspecto relevante identificado en la literatura reciente es el sesgo de las CNNs hacia la textura frente a la forma [47, 48]. A diferencia de la percepción humana, más dependiente de contornos y geometría global, las CNNs extraen la mayor parte de la información discriminativa a partir de patrones locales y microtexturas. Este comportamiento tiene implicaciones directas en la teledetección ecológica, pues especies con copas rugosas, heterogéneas o con estructuras internas complejas generan señales texturales que estos modelos pueden explotar con mayor facilidad, mientras que especies con copas lisas o de límites difusos tienden a resultar más difíciles de delimitar individualmente. En el caso de *Juniperus*, cuya morfología combina bordes irregulares y una textura interna muy marcada, este sesgo sugiere que los modelos de segmentación basados en instancias (más sensibles a patrones locales) podrían beneficiarse especialmente de dicha estructura textural, proporcionando una separación más eficaz de individuos contiguos que los enfoques puramente semánticos.

3 Área de estudio y conjunto de datos

3.1 Descripción del área de estudio: Sierra Nevada

Uno de los sistemas montañosos más singulares del Mediterráneo, situado al sudeste de la Península Ibérica, es Sierra Nevada (Figura 1). Su particularidad nace de su amplio gradiente altitudinal, ya que posee desde laderas bajas en el borde oriental (350 m sobre el nivel del mar) hasta el Mulhacén (3479 m s.n.m.), techo de la Península, además de su posición meridional, la proximidad al Mediterráneo y su elevada diversidad biológica y paisajística. Todos estos factores hacen de este macizo un laboratorio natural perfecto para, por un lado, analizar los efectos del cambio climático sobre los ecosistemas de montaña y, por otro, justificar programas de monitorización de largo plazo como ocurre con el Observatorio de Cambio Global de Sierra Nevada (OSE). Este observatorio pone de manifiesto que el fuerte gradiente altitudinal, la variabilidad climática y la historia natural y de usos del territorio provocan que Sierra Nevada sea un enclave idóneo para la detección y la evaluación de tendencias de cambio en procesos biofísicos clave [49, 50].




Figura 1: a) Área de estudio del presente TFM: Sierra Nevada (Andalucía, SE de España) [51]. b) Imagen de campo de un ejemplar de *Juniperus sabina* presente en Sierra Nevada [52].

En términos climáticos, el macizo de Sierra Nevada comparte las tendencias detectadas en otras cordilleras ibéricas como los Pirineos, con señales robustas de calentamiento y cambios en el régimen de precipitaciones durante el último siglo. De hecho, un análisis reciente realizado para ambos sistemas montañosos (1930–2020), basado en una base de datos homogeneizada de temperatura y precipitación, estima un calentamiento medio de aproximadamente 0.13°C por década en Sierra Nevada y una tendencia negativa (no siempre significativa) en la precipitación anual, coherente con la aridificación mediterránea sufrida. Las implicaciones que conllevan estos factores son notorias y relevantes, como son la reducción de la permanencia del manto nival y la estacionalidad más marcada, teniendo a su vez consecuencias hidrológicas y ecológicas [53].

Tanto en la escala global como regional, el IPCC (*Intergovernmental Panel on Climate Change*) [54, 55] muestra una tendencia generalizada al ascenso altitudinal de los ecotonos (como la línea de árboles) en montañas, con un elevado porcentaje de casos de desplazamiento hacia cotas más altas en las últimas décadas. A pesar de que la temperatura es el

principal controlador del límite superior del bosque, la disponibilidad de agua y los usos del suelo también regulan las respuestas, siendo por ello un matiz relevante en montañas mediterráneas donde el déficit hídrico estival es estructural. Como cabe esperar, estas dinámicas de desplazamiento ascendente afectan negativamente el espacio disponible para las especies arbustivas y pueden incluso transformar su estructura, continuidad y composición.

Dentro de la variabilidad de vegetación en ambientes de alta montaña, destacan los matorrales oromediterráneos dominados por especies de *Juniperus*, la mayoría *Juniperus communis* y *Juniperus sabina*, los cuales son arbustos longevos y polimorfos que generan matrices de vegetación dispersa o coalescente por encima del límite del bosque y que resultan de gran interés de conservación. Hace décadas, ya existían estudios botánicos clásicos y de dinámica poblacional en sistemas mediterráneos altos como Sierra Nevada que mostraban la relevancia de los arbustos *Juniperus* en los xeroacánticos supras y oromediterráneos (tipo de vegetación arbustiva que habita en zonas con propiedades de sequedad y altitud) [56]. Añadido a los estudios anteriores, aparecen nuevos trabajos que aplican series temporales de varias décadas y que confirman que los *Juniperus* combinan gran longevidad con respuestas muy sensibles a pulsos climáticos (sequías o años fríos) que comprometen su crecimiento y reclutamiento, y por consiguiente su capacidad de persistencia en espacios de calentamiento y menor disponibilidad hídrica [57, 58].

Debido a varios motivos, en los últimos años se ha visto reforzado el interés por mapear y seguir a escala fina estos arbustos polimorfos. En primer lugar, estas especies se encargan de realizar funciones esenciales para el ecosistema de montaña, como la estabilización del suelo y la regularización de la humedad superficial, además de que sirven como refugio para fauna y amortiguan la exposición al viento. En segundo lugar, el calentamiento global está provocando la modificación de la dinámica nival y la ventana de crecimiento, provocando también descensos documentados del volumen de nieve estacional y un alargamiento de los períodos donde no hay nieve en las montañas españolas, sin exceptuar Sierra Nevada, teniendo efectos en cascada sobre la fenología y el balance hídrico de los arbustos [59]. En tercer lugar, posibles cambios en el régimen de incendios y otros disturbios alteran la vulnerabilidad de estas especies, añadiendo consigo una complejidad a su gestión. Todas estas razones respaldan estrategias de seguimiento que combinen teledetección de alta resolución y anotaciones de campo.

De esta manera, la teledetección de los *Juniperus* con técnicas de visión por computador en imágenes aéreas de alta resolución se ha consolidado como una vía clave para cuantificar múltiples factores como la distribución, el tamaño de copa de los arbustos, la cobertura e incluso la densidad, aportando así indicadores sensibles al cambio climático. Así pues, el estudio que ha servido de referencia para este TFM y que se ha centrado en Sierra Nevada, ha demostrado la viabilidad de la segmentación de instancias para el mapeo individual de arbustos polimorfos utilizando para ello Mask R-CNN y, además, diseñando una métrica adaptada (S-IoU) que atenúa la penalización por particiones o fusiones en masas coalescentes [10]. Este precedente impulsa la comparación entre diferentes paradigmas (instancia, semántico y panóptico) que se desarrolla en los siguientes apartados.

Para finalizar esta subsección, el enfoque del observatorio en Sierra Nevada mediante protocolos de seguimiento y repositorios de datos multianuales proporciona un marco institucional y científico idóneo para la integración de fuentes como imágenes, datos de campo o modelos y su posterior transferencia. Por otra parte, la disponibilidad de series climáticas regionales y de herramientas de síntesis (fichas y metodologías del OSE) da cabida a la interpretación de los patrones detectados por los modelos en términos ecoló-

gicos, reforzando con ello la utilidad de este caso de estudio y la gestión de espacios de montaña bajo el calentamiento global [49, 50, 53].

3.2 Conjunto de datos. JuniperMapper: AI for Shrub Delineation (DATA)

Este trabajo utiliza dos conjuntos de datos complementarios que permiten la evaluación del rendimiento y la capacidad de generalización de los modelos de segmentación profunda. Dentro del conjunto *JuniperMapper: AI for Shrub Delineation (DATA)*, elaborado para el estudio de Khaldi et al. (2024) y disponible en Zenodo [23], se encuentran los conjuntos Photo Interpretation Data (PI) y Field Work Data (FW). El objetivo de la creación de este dataset fue desarrollar un conjunto de imágenes de muy alta resolución orientado a la detección individual de *Juniperus* en Sierra Nevada (España). El hecho de que existan dos subconjuntos de datos con orígenes y condiciones de adquisición diferentes se basa en la importancia del análisis de la transferibilidad de los modelos de visión por computador entre ambos dominios, es decir, la capacidad del modelo a adaptarse a imágenes obtenidas en contextos ópticos, geométricos y temporales distintos, lo que resulta crucial en el ámbito de la teledetección ecológica.

A continuación, en la Tabla 2, se refleja de manera resumida la distribución de imágenes dentro de cada subconjunto (PI y FW), el número de arbustos presentes en cada uno y según la clasificación por tamaños (de XS a XXL).

Nombre del dataset	Particiones dataset	Tamaño de imagen	Número de imágenes	Número de arbustos						
				All	XS	S	M	L	XL	XXL
Photo Interpreted (PI)	Train	(448 x 448) píxeles 3582.33 m ²	570	5459	559	837	1392	1331	805	535
	Validation		67	660	90	91	152	170	97	60
	PI Test		75	690	29	91	163	201	119	87
Field Work (FW)	FW	(420 x 336) píxeles 2550.68 m ²	124	1771	310	329	439	351	194	148
Total			836	8580	988	1348	2146	2053	1215	830

Tabla 2: Distribución del número de imágenes e instancias en los conjuntos de datos PI y FW según sus particiones internas y el número de arbustos según su tamaño (XS-XXL).

3.2.1 Photo Interpretation Data (PI)

Por un lado, el subconjunto PI corresponde a una colección de parches de imagen tomados de imágenes RGB de muy alta resolución (13 cm/píxel) procedentes de Google Earth. Los parches fueron seleccionados manualmente por un equipo de expertos a partir de áreas de Sierra Nevada donde la presencia de los arbustos *Juniperus* era clara y foto-interpretable. Además, en este conjunto cada parche presenta un tamaño fijo de 448×448 píxeles, lo que corresponde aproximadamente, a una superficie de 3582.33 m².

Para realizar las anotaciones se siguió un proceso de digitalización manual poligonal a partir de fotointerpretación experta, delineando el contorno visible de cada *Juniperus*. En conjunto, todo el dataset PI comprende 712 imágenes con sus respectivas anotaciones en formato COCO (.json). Además, tanto las imágenes como las anotaciones se encuentran divididas en tres particiones independientes espacial y temporalmente: por un lado para el entrenamiento (PI-train), por otro para la validación (PI-val) y por último para la prueba (PI-test) de los modelos, según la estructura proporcionada en el repositorio de Zenodo.

3.2.2 Field Work Data (FW)

Por otro lado, el conjunto FW está formado por 124 parches de imagen extraídas también de imágenes RGB de Google Earth sobre tres zonas donde se realizó un detallado inventario de campo pero, en esta ocasión, los parches tienen un tamaño de 420×336 píxeles. En las zonas estudiadas, el equipo de especialistas registró mediante GPS diferencial centimétrico la localización precisa de cada individuo. Una vez tomados estos datos, se ajustaron de manera manual los contornos sobre las imágenes para generar las anotaciones.

En total, este subconjunto contiene 1771 arbustos anotados y se utiliza únicamente como conjunto de prueba independiente. Cabe añadir también que ninguna de las imágenes se solapa espacialmente con los del otro conjunto, sino que la distancia media entre ambos dominios es de 433 m, garantizando de este modo una evaluación externa en un entorno espacialmente independiente. Con este diseño se puede medir la capacidad de transferencia del modelo entrenado en el conjunto PI cuando se aplica a áreas nuevas y no vistas anteriormente, y que poseen diferentes condiciones de iluminación, cobertura de nieve y estructura de la vegetación.

Por último, las anotaciones de este conjunto también se encuentran en formato COCO (.json) al igual que ocurría para PI. Esta uniformidad permite la compatibilidad para los procesos de entrenamiento, evaluación y conversión posterior a las máscaras semánticas.

3.2.3 Análisis descriptivo de tamaños y cobertura

Antes de realizar el entrenamiento, se hizo un análisis exploratorio sobre las propiedades geométricas de los *Juniperus* en las máscaras binarias del conjunto PI. Para lograrlo se emplearon las librerías *scikit-image* [60] y *pandas* [61], obteniendo métricas de área y perímetro de cada uno de los polígonos presentes en las anotaciones. En función de la distribución del área proyectada, los individuos se clasificaron en seis categorías de tamaño, de acuerdo con la metodología del estudio base (Khaldi et al., 2024 [10]) y, seguidamente, se han reflejado en la Tabla 3:

Categoría	Área (m ²)	Descripción aproximada
XS	< 1	Plántulas o arbustos jóvenes dispersos
S	1 – 2.5	Ejemplares pequeños individuales
M	2.5 – 5	Arbustos maduros aislados
L	5 – 10	Masas compactas de tamaño medio
XL	10 – 20	Arbustos adultos coalescentes
XXL	> 20	Manchas densas o agrupaciones complejas

Tabla 3: Clasificación de los arbustos *Juniperus* por tamaño (en m²) y breve descripción de cada categoría.

Con esta clasificación de los matorrales según su área es posible el análisis del rendimiento de cada modelo por clase de tamaño. Este estudio es crucial en especies polimorfas como *Juniperus*, donde la variabilidad en la forma y la coalescencia afectan notoriamente a las métricas de segmentación (IoU y S-IoU).

Cabe destacar además que, como se ha podido observar en la Tabla 2, existe un significativo sesgo hacia tamaños medianos (categorías M y L), con menor frecuencia en

matorrales con tamaños más extremos (XS y XXL). Por otro lado, se ha calculado la cobertura media por imagen (porcentaje medio de píxeles etiquetados como arbustos frente a fondo), siendo del 5.22 % en PI-train, 5.28 % en PI-val y 6.61 % en PI-test y del 9.03 % en FW, con desviaciones estándar moderadas (7.06 %, 6.62 %, 8.17 % y 11.11 % respectivamente), lo que afirma una representatividad ecológica adecuada para la finalidad de este proyecto.

3.2.4 Visualización de ejemplos

Con el fin de comprender mejor tanto las imágenes con las que se trabaja (imágenes aéreas, no de campo) como las anotaciones que se tienen de ellas, en la Figura 2 se ejemplifica una imagen satelital, a la vez que la anotación en formato COCO que se le ha realizado de forma superpuesta y que utilizan los modelos de segmentación de instancias y la máscara binaria generada, utilizada por los modelos de segmentación semántica.




Figura 2: Ejemplificación gráfica de los datos utilizados: a) Imagen satelital original, b) Imagen satelital con sus anotaciones superpuestas (contornos poligonales en formato .json) que utilizan los modelos de segmentación de instancias y c) Máscara binaria (0 o negro para el fondo y 1 o blanco para el arbusto) que utilizan los modelos de segmentación semántica.

Estas imágenes permiten visualizar el proceso completo de conversión y sirven como referencia para la interpretación de las salidas de los diferentes modelos estudiados en este TFM.

4 Metodología

4.1 Visión general del flujo de trabajo

El objetivo principal de este proyecto es evaluar distintas arquitecturas de segmentación profunda disponibles en Detectron2 [13] para el mapeo individual de arbustos *Juniperus* a partir de imágenes satelitales de alta resolución en Sierra Nevada (España). Para poder llevar esto a cabo, se ha diseñado un flujo de trabajo homogéneo (*pipeline*) que permite comparar de forma justa y equiparable modelos de segmentación de instancias, segmentación semántica y segmentación panóptica, manteniendo constantes para todos los casos el conjunto de datos, las particiones de entrenamiento y validación, y el protocolo final de evaluación.

En líneas generales, el flujo de trabajo completo puede dividirse en seis grandes etapas:

1. Preparación de los datos, conversión de anotaciones y generación de máscaras semánticas.
2. Registro de los conjuntos de datos en Detectron2 según el tipo de segmentación en la que se base el modelo.
3. Configuración y entrenamiento de los modelos.
4. Inferencia y generación de máscaras de predicción.
5. Cálculo de métricas a nivel de instancia y de píxel.
6. Derivación de métricas ecológicamente relevantes (cobertura y densidad de *Juniperus*).

Por lo tanto, en esta subsección se ofrece una visión global y genérica de este proceso, mientras que en las subsecciones siguientes se desarrollan los detalles técnicos específicos de cada etapa.

Bloque 1: preparación de datos, conversión de anotaciones y generación de máscaras semánticas

La preparación de todo el conjunto de datos resulta imprescindible para garantizar la calidad y coherencia del entrenamiento de los modelos de segmentación profunda. Dado que ambos conjuntos (tanto PI como FW) fueron originalmente diseñados para segmentación de instancias con formato COCO (.json), fue necesario llevar a cabo el preprocesamiento de los datos para asegurar la compatibilidad entre paradigmas (instancia, semántico y panóptico).

Por lo tanto, como las anotaciones disponibles sólo podían ser utilizadas por los modelos de segmentación de instancias (Mask R-CNN y PointRend-Instancias) y la rama de instancias de Panoptic FPN, se ha diseñado un proceso de conversión automática para transformar las máscaras de instancias en máscaras binarias semánticas (formato GeoTIFF) aplicables para los modelos de segmentación semántica. De esta manera, se han utilizado dos tipos de anotaciones: anotaciones en formato COCO, que presentan una única clase (*juniper*), y las anotaciones con formato GeoTIFF, que distinguen dos clases (fondo o *background* y *juniper*).

Bloque 2: registro de datasets y configuración común

Una vez preparadas las anotaciones, los diferentes conjuntos de datos se registran en Detectron2 empleando para ello las utilidades DatasetCatalog y MetadataCatalog. Los ficheros COCO se utilizan para los modelos basados en instancias, mientras que los modelos semánticos necesitan las máscaras semánticas binarias. Para Panoptic FPN en concreto, se ha de utilizar ambas anotaciones, tanto los ficheros COCO como las máscaras GeoTIFF.

Además, en este bloque se establecen un conjunto de decisiones comunes que afectan a todos los modelos:

- El número de clases es fija: para las arquitecturas de instancias se establece una única categoría de interés (*juniper*), mientras que para las arquitecturas semánticas se fijan dos clases (*background* y *juniper*).
- Se conservan las propiedades geoespaciales de las ortoimágenes (transformación afín y sistema de referencia de coordenadas), lo que permite más adelante expresar áreas y densidades en unidades físicas (m² e individuos/ha).

- Se emplea un esquema de data augmentation coherente con la naturaleza de las imágenes (rotaciones, volteos, recortes relativos y ligeras transformaciones fotométricas), adaptado en cada modelo para evitar ruido en la interpolación de máscaras.

Bloque 3: entrenamiento de los modelos

Las cinco arquitecturas que se han estudiado en este trabajo han sido las siguientes:

1. Mask R-CNN (*baseline* del artículo original [10]), con arquitectura ResNet-101-C4 y configuración lo más fiel posible al trabajo de referencia.
2. DeepLabV3+, como representante de la segmentación semántica pura, se ha entrenado con máscaras binarias y se ha realizado un posterior conteo de componentes conectados (*Connected Components*, CC) en el posprocesado para recuperar instancias individuales.
3. PointRend-Semántico, que refina los contornos a partir de una máscara semántica inicial para mejorar la precisión en bordes. En este también se aplican Connected Components (CC) en el posprocesado.
4. PointRend-Instancias, que opera directamente en el marco de Mask R-CNN, pero añadiendo una cabeza de refinamiento por puntos sobre las máscaras de instancia.
5. Panoptic FPN, que integra una rama de instancias y otra semántica en un modelo panóptico, aprovechando ambas representaciones durante el entrenamiento, aunque en este trabajo se explota principalmente su salida de instancias.

Estas cinco arquitecturas tienen en común que han sido entrenados sobre PI-train, monitorizando la pérdida y las métricas en PI-val para detectar problemas de sobreajuste y seleccionar el punto de parada adecuado. No obstante, el número de iteraciones, la tasa de aprendizaje (*learning rate*) y el planificador o *scheduler* (por ejemplo, *WarmupCosineLR* en Panoptic FPN) se ajustan para lograr un equilibrio entre rendimiento y coste computacional. En todos los casos se utilizan los pesos preentrenados en COCO (modelos de instancias o panópticos) o Cityscapes (modelos semánticos) proporcionados por Detectron2 como punto de partida.

Bloque 4: inferencia y generación de máscaras de predicción

Tras ser entrenados los modelos, se fijan y se emplean exclusivamente en modo inferencia sobre los conjuntos de test de PI y FW. Para los modelos de instancias (Mask R-CNN, PointRend-Instancias) y Panoptic FPN se obtiene, para cada imagen, un conjunto de máscaras binarias independientes, cada una asociada a un arbusto candidato y a una puntuación de confianza.

En el caso de los modelos semánticos (DeepLabV3+ y PointRend-Semántico), se genera una máscara de probabilidad o de etiquetas para cada píxel, que se convierte en una máscara binaria y posteriormente en instancias mediante un proceso de posprocesado basado en componentes conectados o en segmentación por watershed, según el análisis que se presenta en la Sección 5.

En cualquier caso, las predicciones se guardan como máscaras binarias en formato GeoTIFF, preservando la georreferenciación original de las ortoimágenes. Estas máscaras tienen una doble función: por una parte, permiten reproducir todos los análisis y, por otra, constituyen un producto cartográfico directamente utilizable para aplicaciones de gestión.

Bloque 5: evaluación a nivel de instancia y píxel

Para poder comparar de manera homogénea modelos de naturaleza distinta, se diseña un protocolo de evaluación común que opera exclusivamente sobre la salida binaria de instancias (predichas) y las máscaras de referencia.

En primer lugar, se calculan métricas a nivel de instancia utilizando dos definiciones de solapamiento:

- *Intersection over Union (IoU)* entre pares predicción-etiqueta.
- *Soft IoU (S-IoU)*, una variante adaptada al problema en la que se considera la unión de todas las instancias que solapan con un mismo arbusto, tanto para predicciones como para etiquetas, con el fin de penalizar especialmente las fragmentaciones o fusiones de coronas.

Para cada métrica y umbral de solapamiento (0.5 y 0.75), se construyen matrices de solapamiento y se resuelve una asignación óptima mediante el algoritmo Húngaro (utilizando la implementación `linear_sum_assignment` de SciPy) [62], obteniendo así contadores globales de verdaderos positivos, falsos positivos y falsos negativos. A partir de estos contadores se derivan precisión, exhaustividad (*recall*) y F1-score.

En segundo lugar, se evalúa el comportamiento a nivel de píxel mediante métricas estándar en segmentación semántica: *pixel accuracy*, IoU medio (*mIoU*) e IoU ponderado por frecuencia (*fwIoU*). Estas métricas se calculan sobre máscaras binarias globales obtenidas como la unión de todas las instancias presentes en cada imagen.

Adicionalmente, se estratifican los resultados por clases de tamaño de arbusto, asignando cada instancia (o combinación de instancias solapadas) a un intervalo de área en m^2 a partir del tamaño de píxel (GSD). Esto permite analizar en qué rangos de tamaño cada modelo resulta más fiable.

Finalmente, para cada modelo se genera una familia de curvas $F1-\theta_{score}$, variando el umbral de confianza de las predicciones. El valor θ^* utilizado en la comparación principal se define como aquel que maximiza el F1-score para S-IoU@0.5 en cada conjunto (PI-test y FW), según se estipuló en el artículo base de Khaldi et al. (2024) [10].

Bloque 6: métricas de cobertura y densidad

Más allá de las métricas de segmentación, el trabajo incorpora indicadores con interpretación ecológica directa. A partir de las máscaras de predicción y de referencia a θ^* , se calcula, para cada ortoimagen:

- La cobertura de copa (%), como fracción de píxeles válidos (excluyendo NoData) etiquetados como juniper.
- La densidad de individuos, tanto en número de arbustos por imagen como en número de arbustos por hectárea, combinando el conteo de componentes conectados o watershed con el área válida de cada escena derivada de la georreferenciación.

Se analizan los errores de cobertura y densidad mediante RMSE, MAE, MBE y coeficiente de determinación R^2 , tanto a nivel de imagen como en términos de densidad por hectárea. En el caso de la densidad, se calibra adicionalmente un esquema de watershed sobre FW con el objetivo de ajustar mejor el conteo automático al número de individuos anotados manualmente.

En definitiva, este flujo de trabajo proporciona un marco coherente para comparar distintas arquitecturas de segmentación profunda, no sólo en términos de métricas de segmentación estándar, sino también en cuanto a su capacidad para estimar variables estructurales clave de la vegetación, como la cobertura y la densidad de *Juniperus*.

4.2 Preparación de datos

La preparación del conjunto de datos es una etapa fundamental para garantizar la coherencia entre modelos y facilitar una comparación justa entre arquitecturas de naturaleza distinta. Como se ha detallado en la Sección 3.2, en este trabajo se emplean ortoimágenes satelitales anotadas manualmente, con estructuras internas heterogéneas y transformaciones específicas según cada familia de modelos. Por ello, la preparación se aborda mediante una combinación de procedimientos generales y comunes a todos los modelos, y transformaciones particulares adaptadas a las exigencias de cada arquitectura (segmentación de instancias, segmentación semántica o segmentación panóptica).

En esta sección se describen en detalle la creación de las anotaciones en múltiples formatos, el registro de los conjuntos de datos en Detectron2, la estandarización de tamaño y resolución espacial, el preprocesado fotométrico y geométrico, y los esquemas de data augmentation aplicados, diferenciando entre los distintos modelos entrenados.

4.2.1 Conversión de anotaciones y generación de máscaras semánticas

Para poder llevar a cabo la generación de las máscaras semánticas binarias, fue necesario la implementación de un código en Python, utilizando las librerías Detectron2, NumPy [63] y OpenCV [64] para conservar el tamaño original de las imágenes. Así pues, las máscaras generadas muestran el valor 1 para los píxeles que corresponden a los arbustos (clase juniper), mientras que reflejan el valor 0 para aquellos píxeles que corresponden al fondo (clase background), almacenándose dichas máscaras en formato .tif (mismo formato que las imágenes originales del dataset). Este formato permite su visualización en QGIS o el análisis basado en resolución conocida (en este caso, 13 cm/píxel).

Tras todo este proceso, finalmente han quedado dos tipos de anotaciones:

- Anotaciones de instancias en formato COCO (.json): cada matorral se representa como una instancia individual mediante polígonos que se convierten en máscaras binarias asociadas a un identificador de objeto. Este formato es utilizado por los modelos de segmentación de instancias (Mask R-CNN, PointRend-Instancias y la rama de instancias de Panoptic FPN).
- Máscaras semánticas binarias con formato GeoTIFF (.tif): a partir de las mismas anotaciones se genera una máscara por cada imagen con dos clases (background y juniper), en la que todos los píxeles pertenecientes a cualquier arbusto comparten la misma etiqueta. En esta ocasión, son los modelos de segmentación semántica (DeepLabV3+ y PointRend-Semántico) y la rama semántica de Panoptic FPN los que utilizan estas máscaras.

4.2.2 Registro de los datasets en Detectron2

A continuación, se integraron los distintos formatos de datos en el ecosistema de Detectron2, empleando las funciones `register_coco_instances` y `DatasetCatalog`. Al existir tres tipos diferentes de segmentación (de instancias, semántica y panóptica), se realizaron tres tipos de registros:

a) Registros COCO (instancias)

En este caso, se registraron cuatro conjuntos: `pi_train_coco`, `pi_val_coco`, `pi_test_coco` y `fw_test_coco`. Estos se utilizan en los modelos de instancias, así como en Panoptic FPN para la rama basada en instancias.

b) Inyección de máscaras semánticas para Panoptic FPN

Panoptic FPN requiere, añadido a lo anterior, una máscara semántica asociada a cada imagen. Para ello, se registraron los conjuntos `pi_train_panoptic` y `pi_val_panoptic`, donde a cada entrada COCO se le añade un campo adicional:

$$d["sem_seg_file_name"] = \text{ruta de la máscara semántica en formato GeoTIFF.}$$

Al tener ambos tipos de segmentación, los metadatos asociaron una única clase de instancia (juniper) y dos clases semánticas (background, juniper).

c) Registros de máscaras semánticas puras

Para DeepLabV3+ y PointRend-Semántico, sólo se utilizaron las rutas a las máscaras binarias GeoTIFF y sus imágenes originales correspondientes.

4.2.3 Estandarización de tamaño y resolución

Las imágenes originales presentan ligeras variaciones en resolución espacial (*Ground Sampling Distance*, GSD) y dimensiones. No se realizó un remuestreo explícito para homogeneizar GSD, con el fin de evitar alteraciones fotométricas y espaciales innecesarias. En su lugar, la estandarización se realizó dinámicamente mediante transformaciones de redimensionamiento (*resize*) aplicadas en cada modelo durante el entrenamiento:

- Modelos de instancias: Usan `ResizeShortestEdge` con múltiplos entre 800 y 1200 px y límite máximo de 1600 px, preservando proporciones y manteniendo la escala relativa de detalles finos.
- Modelos semánticos: DeepLabV3+ exige dimensiones compatibles con la tasa de submuestreo (*downsampling*) del backbone (múltiplos de 32). Por ende, se fijó un tamaño rectangular uniforme para evitar errores arquitectónicos.
- Panoptic FPN: adopta un modo de multirresolución con tamaños entre 320 y 512 px en el lado corto.

El tamaño de píxel (GSD) se conserva en los metadatos, lo que permite convertir áreas de píxeles a áreas físicas en m^2 mediante la expresión 4.1:

$$\text{Área (m}^2\text{)} = \text{n}^\circ \text{ de píxeles} \times \text{GSD}^2. \quad (4.1)$$

4.2.4 Normalización radiométrica y preprocesado fotométrico

Se aplicó una normalización mínima para no distorsionar la información espectral contenida en la imagen:

- Las imágenes se leyeron directamente en su rango original de valores (8 o 16 bits según la escena).

- No se aplicó normalización per-canal ni estandarización global.

Esta decisión se basa en dos consideraciones:

1. En este trabajo se observa que los modelos de visión por computador preentrenados en COCO presentan una buena robustez frente a rangos dinámicos no estandarizados, incluso sin normalizar radiométricamente las imágenes.
2. Al no modificar los valores radiométricos originales, se evita introducir sesgos que podrían afectar a métricas ecológicas dependientes de la morfología del arbusto.

Por último, se empleó conversión a BGR sólo cuando lo requirió Detectron2 (para modelos basados en DefaultPredictor).

4.2.5 Esquemas de data augmentation

El objetivo principal de aplicar data augmentation sobre los datos es aumentar la robustez de los modelos ante variaciones geométricas y radiométricas, además de evitar posibles inconsistencias en las máscaras que comprometan la coherencia entre clases. Por consiguiente, se aplicaron las siguientes transformaciones:

Transformaciones geométricas

- Volteo horizontal y vertical.
- Rotaciones aleatorias de pequeño ángulo ($[-10^\circ, 10^\circ]$) o rotaciones a múltiplos de 90° según el modelo.
- Redimensionamiento multiescala manteniendo las proporciones.
- Recortes relativos (RandomCrop) entre el 70 % y el 90 % del tamaño original.

Cabe destacar que todas estas operaciones se aplicaron de forma consistente a imágenes, máscaras de instancia y bounding boxes, garantizando así la integridad geométrica.

Transformaciones fotométricas

En este caso, se aplicaron transformaciones muy leves para no distorsionar el contraste natural de la vegetación:

- Brillo, contraste y saturación con factores entre 0.85 y 1.15.
- En PointRend-Semántico y DeepLabV3+ se utilizaron perturbaciones ligeramente más suaves para preservar el detalle en los bordes.

Adaptación según arquitectura

- En los modelos semánticos se evitaron rotaciones agresivas cuando existía riesgo de *aliasing* en bordes finos, es decir, se querían evitar distorsiones que aparecen cuando una imagen tiene más detalle del que la resolución puede representar.
- En los modelos de instancias se permitieron augmentations más fuertes, mientras las cajas pudieran recalcularse sin pérdida de coherencia.
- Con Panoptic FPN se empleó un conjunto propio de augmentations específicas para entrenamiento panóptico, incluyendo rotaciones exactas de 0° , 90° , 180° y 270° .

4.2.6 Preprocesado específico por tipo de modelo

Puesto que cada arquitectura requiere un formato de entrada distinto, se establecieron tres tipos de pipelines:

a) Modelos de instancias

Por un lado, Mask R-CNN, PointRend-Instancias y la rama de instancias de Panoptic FPN emplean anotaciones COCO, por lo que se requiere:

- Máscaras por instancia (*bitmask*) o polígonos.
- Recomputación de cajas tras las transformaciones geométricas.
- Ajustes específicos en el generador de anclas (*anchors*) para capturar objetos pequeños.

b) Modelos de segmentación semántica

Por otro lado, los modelos DeepLabV3+ y PointRend-Semántico trabajan con una máscara por imagen, por lo tanto:

- Se emplean los GeoTIFF semánticos generados a partir de las anotaciones originales.
- Las máscaras deben estar alineadas espacialmente con cada imagen incluso tras las transformaciones.
- Estos modelos sólo producen una única máscara binaria, por lo tanto, la recuperación de instancias se realiza en el posprocesado mediante componentes conectados o watershed.

c) Modelos panópticos

Por último, Panoptic FPN utiliza tanto el fichero COCO con las instancias como la máscara semántica por imagen. Además, la rama semántica usa pérdida ponderada y la rama de instancias sigue la lógica de Mask R-CNN, fusionándose finalmente ambas predicciones en una representación panóptica.

En líneas generales, el preprocesado detallado en esta sección cubre las necesidades concretas de cada arquitectura, a la vez que garantiza la coherencia entre los productos generados y su comparabilidad en las etapas siguientes de evaluación.

4.3 Modelos de segmentación

A continuación, se han descrito las configuraciones de cada uno de los modelos que este TFM pretende evaluar, Mask R-CNN y PointRend-Instancias (segmentación de instancias), DeepLabV3+ y PointRend-Semántico (segmentación semántica) y Panoptic FPN (segmentación panóptica). Cabe recalcar el hecho de que todas ellas se entrenaron sobre el conjunto PI-train, se validaron en PI-val y se evaluaron en PI-test y FW siguiendo un protocolo unificado. Adicionalmente, cada modelo se configuró de forma coherente con sus capacidades y con las especificidades del conjunto de datos, respetando estrictamente las configuraciones reproducidas del artículo original en el caso de Mask R-CNN [10].

Así pues, en las siguientes subsecciones se describe cada arquitectura, además de su configuración, los hiperparámetros utilizados, el esquema de data augmentation, las estrategias de entrenamiento y el procedimiento de inferencia.

4.3.1 Mask R-CNN (baseline del artículo original)

Como referencia principal se replica el modelo utilizado en el artículo de Khaldi et al. (2024) [10], que emplea la arquitectura Mask R-CNN con un backbone ResNet-101 en la variante C4. Este modelo se entrenó exclusivamente sobre la región PI, sin aplicar técnicas de data augmentation más allá de las incluidas por defecto en Detectron2, siguiendo el razonamiento del trabajo original.

El modelo opera bajo el paradigma de segmentación de instancias: para cada imagen, el RPN genera un conjunto de propuestas, que posteriormente son refinadas por la cabeza ROI para obtener bounding boxes, puntuaciones de confianza y máscaras binarias por instancia. No se utilizaron anchors personalizados ni modificaciones en el RPN, manteniendo así la configuración estándar de Mask R-CNN para permitir una comparación directa con los modelos más avanzados empleados en este TFM.

Los hiperparámetros principales replican la configuración descrita en el artículo base [10]:

- Backbone: ResNet-101-C4.
- Preentrenamiento: pesos COCO oficiales.
- Número de clases: 1 (juniper).
- Entrenamiento: 4000 iteraciones, con learning rate inicial de 0.0025 y un planificador WarmupCosine con 2000 iteraciones de warmup y decaimiento cosenoidal.
- Resolución: redimensionado automático sin normalización adicional.
- Salida: máscaras de instancia.

Este modelo sirve como base para la evaluación tanto de las posibles mejoras introducidas por modelos modernos de segmentación semántica y panóptica como de las ganancias obtenidas mediante arquitecturas especializadas en el refinamiento de bordes, como PointRend.

4.3.2 PointRend (segmentación de instancias)

En la variante de instancias, PointRend se integra directamente sobre Mask R-CNN, añadiendo una cabeza adicional para refinar los contornos de cada máscara de instancia. El modelo utilizado corresponde a la configuración `pointrend_rcnn_R_50_FPN_3x`, adaptada a una única clase de objeto (*Juniperus*).

El entrenamiento se llevó a cabo sobre PI-train, aplicando un conjunto de augmentations compatibles con instancias (flips, rotaciones suaves, recortes, ajustes fotométricos). El modelo emplea una estrategia multietapa de refinamiento de máscaras, en la que sucesivas iteraciones de muestreo permiten representar con alta fidelidad los bordes de los arbustos.

Esta configuración incluye los siguientes hiperparámetros:

- Backbone: ResNet-50-FPN.
- Preentnameinto: pesos COCO oficiales.
- Clases: 1 (juniper).

- Anchors personalizados: tamaños [8, 16, 32, 64, 128] px y razón de aspecto 1:1 para adaptarse a arbustos pequeños.
- Máscara ROI: resolución 28×28 , 6 convoluciones, peso de pérdida ampliado.
- Cabeza PointRend: 4096 puntos en entrenamiento; 8192 en inferencia.
- Entrenamiento: 10000 iteraciones, con learning rate base de $1 \cdot 10^{-3}$ con descenso de learning rate en la iteración 8000.
- AMP: entrenamiento en precisión mixta activado.
- Gradiente: recorte de gradiente con valor 1.0.

La inferencia genera un conjunto de máscaras de instancias y sus puntuaciones. Posteriormente, se aplica un filtrado por umbral y una fusión rápida basada en IoU para eliminar duplicados antes del cálculo de métricas.

4.3.3 DeepLabV3+ (segmentación semántica)

El modelo DeepLabV3+ representa la familia de arquitecturas de segmentación semántica, en la que se predice directamente una máscara de clases por píxel. Siguiendo la implementación disponible en Detectron2, este modelo se entrenó exclusivamente con las máscaras semánticas binarias generadas a partir de las anotaciones originales.

Cabe destacar que DeepLab realiza un downsampling fijo en potencias de 2 por lo que se tuvo que fijar el tamaño de entrada para así evitar inconsistencias arquitectónicas. En particular, se adoptó una redimensión determinista compatible con *stride* 16, como se indica en el código base.

La predicción resultante es una máscara semántica binaria por imagen. Tras el entrenamiento, y con el fin de poder comparar este modelo con los de segmentación de instancias, se recuperaron las instancias individuales en el posprocesado mediante componentes conectados (Connected Components) o, en el caso del análisis espacial, mediante segmentación por watershed cuando fue relevante.

Para este caso, los principales hiperparámetros utilizados fueron:

- Arquitectura: DeepLabV3+ con backbone ResNet-103 configurado para output stride de 16 y multigrid 1-2-4.
- Preentrenamiento: pesos Cityscapes oficiales.
- Clases: 2 (background y juniper).
- Entrenamiento: 12000 iteraciones con learning rate inicial de $2 \cdot 10^{-4}$ con 500 iteraciones de *warmup*.
- Augmentations: flip horizontal aleatorio y recortes relativos.
- Salida: máscara semántica binaria, procesada posteriormente para obtener instancias.

4.3.4 PointRend-Semántico (segmentación semántica)

Como ya se ha explicado en el Marco bibliográfico (Sección 2.2), PointRend-Semántico extiende un modelo de segmentación semántica convencional añadiendo para ello una cabeza de refinamiento basada en muestreo de puntos de alta incertidumbre. El principal beneficio de esta técnica es la obtención de contornos significativamente más nítidos que los producidos por una máscara semántica estándar, lo que resulta especialmente útil en coronas arbustivas con límites difusos o parcialmente solapados.

Durante el entrenamiento, además de la imagen de entrada, se utiliza la máscara semántica de cada imagen, indicada en el dataset mediante el campo `sem_seg_file_name`. El entrenamiento se realiza con las mismas particiones PI-train/PI-val que el resto de modelos. Finalmente, la salida es una máscara semántica binaria refinada y, al igual que en DeepLabV3+, esta se convierte en instancias mediante componentes conectados o watershed, según las necesidades del contexto.

Los hiperparámetros principales son:

- Backbone: ResNet-101-FPN.
- Preentrenamiento: pesos Cityscapes oficiales.
- Cabeza PointRend: refinamiento iterativo mediante muestreo de puntos con alta entropía, empleando 1024 puntos por iteración con *oversampling* con un ratio de 3.0 e *importance sampling* (0.5).
- Clases: 2 (semántica).
- Entrenamiento: 6500 iteraciones con learning rate inicial de $2 \cdot 10^{-4}$ y reducción del orden del 90 % en la iteración 4500.
- Redimensionado: escalas multirresolución.
- Augmentations: transformaciones geométricas suaves y ajustes fotométricos leves realizados de manera aleatoria. Flips horizontales y verticales, rotaciones $[-10^\circ, 10^\circ]$, recortes (0.7×0.7), cambio de brillo y contraste (ambos entre 0.9 y 1.1) y cambios de saturación (0.95, 1.05).

4.3.5 Panoptic FPN (segmentación panóptica)

Panoptic FPN combina en una misma arquitectura una rama de segmentación de instancias (basada en Mask R-CNN) y una rama de segmentación semántica. En este trabajo se aprovechan ambas ramas durante el entrenamiento, pero la evaluación se centra en la salida de instancias, coherente con el resto de modelos analizados.

Para entrenar Panoptic FPN fue necesario inyectar simultáneamente las anotaciones COCO y las máscaras semánticas mediante los conjuntos `pi_train_panoptic` y `pi_val_panoptic`. La rama semántica opera con dos clases (fondo y juniper), mientras que la rama de instancias trabaja con una sola clase de objeto.

Para este último modelo, la configuración es la siguiente:

- Backbone: ResNet-101-FPN.
- Preentrenamiento: pesos COCO para el modelo panóptico.
- Ramas:

- Instancias: ROIHeads con 1 clase.
- Semántica: cabeza semántica con 2 clases y peso de pérdida 0.5.
- Anchors personalizados: tamaños [12, 24, 48, 96, 192] px y razones de aspecto [0.5, 1, 2].
- RPN: límite de propuestas adaptado a arbustos densos (hasta 2000 en entrenamiento).
- Entrenamiento: 12000 iteraciones con learning rate base de 0.0025 y WarmupCosineLR, 1200 iteraciones de calentamiento.
- Resizing multiescala: lado corto en [320, 512].
- Augmentations: rotaciones 0°, 90°, 180° y 270°. También fotométricas como cambios de brillo, contraste y saturación en el rango [0.85, 1.15].
- AMP y gradiente: activados.

A la hora de realizar la inferencia, sólo se utiliza la rama de instancias. Entonces, para cada imagen se aplica una predicción única y fusión rápida basada en IoU (0.85) para eliminar duplicados y filtrando por umbral de confianza.

El conjunto final de máscaras se emplea para calcular IoU, S-IoU, métricas pixelares y métricas espaciales siguiendo el protocolo común.

4.3.6 Resumen comparativo de configuraciones

En la Tabla 4 se presenta un resumen de las características principales de cada modelo: paradigma, backbone, formato de anotación empleado, resoluciones, esquema de augmentations y número de iteraciones.

Modelo	Paradigma	Backbone	Entrada	Iteraciones	LR / Optimizador	Scheduler / Augmentations
Mask R-CNN	Instancias	R101-C4	COCO	4000	0.0025/SGD	WarmupCosine (2000 it., $\times 10$); Sin augmentations
PointRend-Instancias	Instancias	R50-FPN	COCO	10000	$1 \cdot 10^{-3}$ // SGD	MultiStep LR warmup 8000its., $\gamma = 0.1$; Flip H/V, rot ($\pm 10^\circ$), redimension, recorte, brillo, contraste, saturación
DeepLabV3+	Semántica	ResNet-103-OS16 (mg=1,2,4)	Máscara semántica	12000	$2 \cdot 10^{-4}$ / SGD	DeepLab LR scheduler (polynomialvdecay warmup 500 its.); Flip H, recorte
PointRend-Semántico	Semántica	R101-FPN	Máscara semántica	6500	$2 \cdot 10^{-4}$ / SGD	multistep LR decay 4500, $\gamma=0.1$; redimensión, flip H/V, rot ($\pm 10^\circ$), recorte, brillo, contraste y saturación
Panoptic FPN	Panóptica	R101-FPN	COCO	12000	0.0025/SGD	WarmupCosineLR, 1200; rotación 0°, 90°, 180° y 270°, brillo, contraste y saturación [0.85, 1.15]

Tabla 4: Resumen de las configuraciones de los modelos evaluados.

Cada modelo se entrena con sus hiperparámetros óptimos internos; sin embargo, todos ellos se evaluaron bajo el mismo protocolo, descrito en detalle en la Sección 4.4.

4.4 Evaluación y métricas

La variedad de métodos empleados en este trabajo genera diferentes tipos de salidas (máscaras de instancia, máscaras semánticas y salidas panópticas). Para poder garantizar una comparación coherente entre modelos heterogéneos, se diseñó un protocolo uniforme de evaluación estructurado en cuatro niveles: métricas por instancia, métricas estructurales basadas en *Hungarian Matching*, métricas por píxel y métricas espaciales agregadas (cobertura y densidad). En suma, se llevó a cabo una calibración del umbral óptimo de puntuación de confianza (θ^*) para todos los modelos con salida de instancias.

A continuación, la Figura 3 resume visualmente el flujo de evaluación seguido.




Figura 3: Flujo de evaluación implementado en este trabajo, común a todos los modelos probados. Incluye filtrado por umbral calibrado, métricas por instancia y por píxel, generación de máscaras binarias, posprocesado por watershed y cálculo de cobertura, densidad y métricas de instancia por tamaño.

4.4.1 Métricas a nivel de instancia

Los modelos Mask R-CNN, PointRend-Instancias y Panoptic FPN generan como salida un conjunto de máscaras individuales por imagen. Para comparar estas predicciones con las imágenes *ground truth* en formato COCO, fue necesario resolver el problema de correspondencia entre predicciones y objetos reales. Se emplearon dos métricas estándar en segmentación de instancias:

1. IoU clásico por instancia.
2. S-IoU, métrica propuesta en el artículo original [10] para una correspondencia más informativa en objetos parcialmente solapados.

1. IoU por instancia con asignación húngara

Para medir IoU de manera global y evitar conteos ambiguos cuando varias predicciones solapan un mismo arbusto, se construye una matriz de IoU de dimensión $N_p \times N_g$, siendo N_p y N_g el número de predicciones y de objetos reales respectivamente. El emparejamiento se resuelve usando el algoritmo Húngaro (`linear_sum_assignment`) aplicado sobre un coste $c_{ij} = 1 - \text{IoU}_{ij}$.

Una vez resuelto el emparejamiento, se clasifican las predicciones en:

$$\text{TP} = \{(i, j) : \text{IoU}_{ij} \geq \tau\}, \text{FP} = N_p - \text{TP}, \text{FN} = N_g - \text{TP},$$

con umbrales $\tau = 0.5$ y $\tau = 0.75$, proporcionando precisión, recall y F1 globales. De esta manera, este procedimiento está implementado en la función:

`eval_iou_at_threshold_hungarian()`

2. S-IoU (Soft IoU)

La métrica S-IoU compara las máscaras de forma distinta al IoU clásico: cada máscara predicha se evalúa respecto al *union set* de todas las máscaras reales con las que solapa (y viceversa para las etiquetas). Esto evita penalizar predicciones correctas cuando las anotaciones manuales agrupan ramas de un arbusto en múltiples polígonos. En esta ocasión, la evaluación se implementa en:

`eval_siou_at_threshold()`

De nuevo, este procedimiento se realizó para $\tau = 0.5$ y $\tau = 0.75$.

4.4.2 Métricas a nivel de píxel

Además de evaluar objetos individuales, es importante cuantificar la calidad de la segmentación a nivel temático. Las máscaras binarias de predicción y realidad terreno se comparan mediante una matriz de confusión pixelar:

$$\text{TP} = \sum \mathbb{1}(\hat{y} = 1 \wedge y = 1), \text{FP} = \sum \mathbb{1}(\hat{y} = 1 \wedge y = 0), \text{etc.}$$

A partir de ella se obtienen las métricas de la expresión 4.2:

$$\text{pACC} = \frac{\text{TP} + \text{TN}}{\text{Total}}, \quad \text{IoU}_{fg} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}}, \quad \text{IoU}_{bg} = \frac{\text{TN}}{\text{TN} + \text{FP} + \text{FN}}. \quad (4.2)$$

Las métricas agregadas son:

- mIoU: es la media de IoU de las dos clases.
- fwIoU: es la IoU ponderada por la frecuencia de cada clase.

Cabe aclarar que estas métricas se calcularon tanto durante el barrido de θ como en la evaluación final. Para ello, la función principal fue:

```
pixel_metrics()
```

Para las máscaras GeoTIFF finales se utilizó una versión que respeta los píxeles No-Data:

```
miou_pixacc_fwIoU_folder()
```

4.4.3 Selección del umbral óptimo θ^*

Los modelos de instancias dependen de un umbral de confianza para filtrar predicciones (*score threshold*). En lugar de fijar un valor arbitrario, se calibró un umbral óptimo θ^* mediante un barrido sistemático:

$$\theta \in [0.05, 0.95] \text{ con incrementos de } 0.05.$$

Para cada θ se calcularon cuatro curvas:

- $F1_{IoU@0.5}(\theta)$
- $F1_{IoU@0.75}(\theta)$
- $F1_{S-IoU@0.5}(\theta)$
- $F1_{S-IoU@0.75}(\theta)$

Siguiendo el artículo original [10], θ^* se definió según la ecuación 4.3 y computado para PI y FW por separado:

$$\theta^* = \arg \max_{\theta} F1_{S-IoU@0.5}(\theta), \quad (4.3)$$

De esta manera, la función que ejecuta el barrido completo es:

```
sweep_theta()
```

y genera:

1. CSV con las curvas de métricas.
2. Figura PNG de las cuatro curvas.
3. Valor óptimo θ^* .

4.4.4 Métricas espaciales: cobertura y densidad

Más allá de la segmentación, este trabajo evalúa métricas ecológicas útiles para gestión forestal: la cobertura arbustiva (porcentaje de píxel cubierto por vegetación) y la densidad de individuos (número de arbustos por imagen o por hectárea).

Cobertura

Para cada imagen se obtiene, según la ecuación 4.4:

$$\text{Cover}_T = \frac{\sum y = 1}{\text{píxeles válidos}}, \quad \text{Cover}_P = \frac{\sum \hat{y} = 1}{\text{píxeles válidos}}. \quad (4.4)$$

Por otro lado, la comparación se realiza mediante $\text{RMSE}_{\text{cover}}$, $\text{MAE}_{\text{cover}}$, $\text{MBE}_{\text{cover}}$ y R^2 . La implementación final, con compatibilidad para máscaras NoData, se encuentra en:

```
coverage_density_from_folders()
```

Densidad (conteo)

Se evalúan dos tipos:

- Densidad absoluta: número de objetos por imagen.
- Densidad por hectárea: número de objetos / área útil (ha).

La detección de individuos se obtuvo mediante Connected Components (CC) como método base y watershed (WS) como método avanzado para separar coronas solapadas. De este modo, se usó para su implementación la función:

```
eval_density_per_ha()
```

Calibración del watershed

Para FW se realizó una búsqueda en rejilla:

$$\text{min_dist_px} \in \{2, 3, 4, 5, 6, 7\}, \quad h \in \{0.05, 0.08, 0.10, 0.12, 0.15, 0.20\}.$$

La función:

```
calibrate_ws_density()
```

selecciona la combinación que minimiza el RMSE de densidad.

4.4.5 Posprocesado: segmentación por watershed (WS)

Muchos arbustos del conjunto FW muestran coronas solapadas que tienden a fusionarse en una única región en las predicciones semánticas. Para desagregar correctamente individuos adyacentes, se empleó un algoritmo watershed basado en la transformada de distancia:

$$\text{dist} = \text{EDT}(\hat{Y}), \quad \text{markers} = \text{local maxima}(\text{dist}).$$

La profundidad de los mínimos y la distancia mínima entre marcadores se ajustaron mediante los parámetros $(\text{min_dist_px}, h)$ optimizados. El módulo correspondiente es:

```
split_ws_pred()
```

Este método se aplica únicamente para las métricas espaciales, no para el cómputo de IoU/S-IoU.

4.4.6 Criterios comparativos y resumen de evaluación

Todos los modelos se evaluaron en PI-test y FW siguiendo exactamente el mismo procedimiento:

1. Predicción por imagen.
2. Filtrado de instancias por θ^* .
3. Fusión rápida de duplicados mediante IoU=0.85.
4. Cálculo de:
 - IoU@0.5, IoU@0.75.
 - S-IoU@0.5, S-IoU@0.75.
 - pACC, mIoU, fwIoU.
 - Cobertura predicha vs observada.
 - Densidad (absoluta y por ha) con y sin WS.
5. Generación de:
 - Tablas globales (TP, FP, FN, F1).
 - Tablas *size-wise* según la discretización del área.
 - Gráficos *scatter* cobertura/densidad.
 - Barras comparativas por bin de tamaño.

El uso de un protocolo homogéneo permite comparar directamente modelos semánticos, de instancias y panópticos pese a producir salidas de naturaleza distinta. El conjunto final de métricas se presenta en el apartado de Resultados (Sección 5).

5 Resultados

A continuación, se detallan los resultados obtenidos y su discusión para cada una de las cinco arquitecturas, tanto a nivel global (para hacer una comparación eficiente entre ellos) como a nivel específico, además de añadir ejemplos de predicciones que realizan estos modelos. En esta sección, se presentan las principales figuras y métricas cuantitativas obtenidas, aunque en Anexos 7 se muestran más tablas y figuras para aportar más información y detalle al análisis.

5.1 Comparación global de arquitecturas

En esta sección se comparan de forma conjunta las cinco arquitecturas evaluadas en el conjunto FW: Mask R-CNN, DeepLabV3+, PointRend-Instancias, PointRend-Semántico y Panoptic FPN. Este conjunto constituye la evaluación externa del sistema y, por tanto, es el escenario más exigente y representativo para medir la capacidad real de generalización de cada modelo.

Este análisis integra las métricas principales de rendimiento por instancia (F1 basado en S-IoU@0.5), la coherencia espacial de las máscaras (mIoU), el comportamiento por clases de tamaño y la capacidad para reproducir patrones ecológicos (cobertura y densidad). Finalmente, se sintetizan los resultados mediante representaciones globales (*trade-off* entre métricas, radar normalizado y matriz comparativa).

5.1.1 Métricas clave en FW

La Tabla 5 resume las métricas centrales de cada arquitectura:

- F1 basado en S-IoU a umbral 0.5 (precisión por instancia).
- mIoU (fidelidad espacial).
- Errores en cobertura y densidad, junto con sus respectivos R^2 .

Modelo	Principales métricas conjunto FW					
	F1 (S-IoU@0.5) (%)	mIoU	Cobertura		Densidad	
			RMSE (%)	R^2	RMSE (ind/ha)	R^2
Mask R-CNN	77.87	0.82	6.62	0.64	19.49	0.91
DeepLabV3+	70.19	0.83	2.96	0.93	40.10	0.63
PointRend-Instancias	74.17	0.83	4.49	0.84	27.56	0.83
PointRend-Semántico	67.49	0.79	6.19	0.69	49.34	0.44
Panoptic FPN	72.66	0.81	5.45	0.76	25.36	0.85

Tabla 5: Métricas principales de las cinco arquitecturas en el conjunto FW.

Los resultados muestran tres patrones principales. En primer lugar, Mask R-CNN alcanza el mejor F1 (77.87 %) y el mayor R^2 en densidad (0.91), lo que indica una excelente precisión individual y una capacidad sólida para estimar indicadores ecológicos derivados. En segundo lugar, DeepLabV3+ y PointRend-Instancias obtienen los mayores mIoU (0.83), reflejando máscaras espacialmente más consistentes, aunque con menor precisión individual que Mask R-CNN. En tercer lugar, Panoptic FPN exhibe un rendimiento equilibrado en todas las métricas, situándose de forma consistente en posiciones intermedias.

Por otro lado, PointRend-Semántico obtiene los valores más bajos tanto en F1 como en mIoU y presenta los mayores errores en densidad, lo que evidencia las limitaciones del enfoque puramente semántico en un problema donde la individualización de copas es crucial.

En líneas generales, y como era de esperar por la naturaleza de los modelos, las arquitecturas basadas en instancias muestran una ventaja clara en precisión individual, mientras que los modelos semánticos tienden a priorizar la coherencia espacial a costa de una reducción en la identificación de objetos individuales, especialmente DeepLabV3+ muestra una mayor coherencia espacial.

5.1.2 Comparación de rendimiento por tamaño de arbusto

La Tabla 6 detalla el F1 por clases de tamaño (XS–XXL), lo cual es especialmente relevante dada la alta variabilidad morfológica de *Juniperus*.

Modelo	Tamaño						
	XS	S	M	L	XL	XXL	All
Mask R-CNN	66.88	75.11	76.72	87.80	89.01	83.82	78.60
DeepLabV3+	32.49	52.76	65.34	77.90	82.96	68.99	65.90
PointRend-Instancias	69.10	80.09	82.85	84.21	75.59	60.00	76.51
PointRend-Semántico	47.76	50.66	55.77	62.28	62.55	25.29	47.09
Panoptic FPN	70.88	72.35	76.77	81.15	77.28	70.14	75.56

Tabla 6: F1-score (%) por clase de tamaño de arbusto para las cinco arquitecturas.

Todos los modelos muestran una pérdida de rendimiento significativa en los tamaños más pequeños (XS y S), donde la resolución limita la capacidad para separar ejemplares pequeños y próximos. Sin embargo, existen diferencias claras entre arquitecturas.

Mask R-CNN y PointRend-Instancias mantienen valores altos y estables a partir de la clase M, lo que evidencia su fortaleza para identificar copas bien definidas y evitar fusiones entre individuos; no obstante, en el caso de PointRend-Instancias se observa una caída de F1 con respecto al tamaño XXL. Panoptic FPN presenta un comportamiento homogéneo en todas las clases, sin alcanzar los valores máximos de Mask R-CNN pero evitando caídas pronunciadas. En contraste, DeepLabV3+ y, especialmente, PointRend-Semántico muestran descensos acusados en XS, lo que confirma la mayor sensibilidad de los enfoques semánticos a la detección de estructuras pequeñas.

Cabe destacar también que es común en todos los modelos observar un descenso en el tamaño de arbusto XXL (aunque en diferente medida), lo que puede deberse a que estos modelos no consiguen detectar la copa en su totalidad, o se confunden con sombras o rocas contiguas.

5.1.3 Relación entre precisión individual y fidelidad espacial

La Figura 4 muestra el compromiso entre precisión individual (S-IoU) y fidelidad espacial (mIoU).




Figura 4: Compromiso entre precisión individual (S-IoU) y fidelidad espacial (mIoU) para todas las arquitecturas dentro del conjunto FW.

Este diagrama revela tres grupos bien diferenciados. Mask R-CNN se posiciona como el modelo más equilibrado, combinando la mayor precisión individual con una alta coherencia espacial. DeepLabV3+ y PointRend-Instancias forman un segundo grupo ca-

racterizado por mIoU elevados pero menor F1 que Mask R-CNN. Por último, PointRend-Semántico se sitúa claramente por debajo en ambos ejes, confirmando su menor capacidad para representar estructuras individuales.

5.1.4 Comparación global mediante radar de métricas

La Figura 5 sintetiza el comportamiento de cada modelo mediante métricas normalizadas.




Figura 5: Radar comparativo de métricas normalizadas en FW (escala [0,1]).

El radar confirma la superioridad de Mask R-CNN en F1 y R^2 de densidad. DeepLabV3+ y PointRend-Instancias destacan en mIoU, mientras que Panoptic FPN se mantiene equilibrado, sin liderar pero sin presentar debilidades marcadas. PointRend-Semántico ocupa consistentemente la menor área, reforzando los patrones observados en las tablas previas.

5.1.5 Matriz de resumen normalizado

Por último, la Figura 6 presenta un resumen compacto del rendimiento relativo entre modelos.

Resumen comparativo de rendimiento relativo (normalizado)

Modelo	Mask R-CNN	1.00	0.75	1.00	1.00
	PointRend-Inst	0.64	1.00	0.83	0.52
	Panoptic FPN	0.50	0.50	0.87	0.62
	DeepLabV3+	0.26	1.00	0.40	0.15
	PointRend-Sem	0.00	0.00	0.00	0.00
		F1(S-IoU@0.5)	mIoU	R2_Dens	RMSE_inv
		Métrica			

Figura 6: Matriz de rendimiento relativo normalizado para todos los modelos.

Esta representación confirma las tendencias anteriores: Mask R-CNN domina en métricas de instancia, PointRend-Instancias y DeepLabV3+ lideran en coherencia espacial, Panoptic FPN ofrece una respuesta sólida y consistente, y PointRend-Semántico se sitúa claramente como el modelo con menor rendimiento global.

5.1.6 Síntesis: ranking de modelos

Integrando todas las métricas y visualizaciones, se establece el siguiente ranking global:

1. **Mask R-CNN**: mejor rendimiento general; máxima precisión individual y excelente estimación de densidad.
2. **PointRend-Instancias**: máxima coherencia espacial (mIoU) junto con DeepLabV3+ y buen equilibrio general.
3. **Panoptic FPN**: comportamiento estable y equilibrado.
4. **DeepLabV3+**: alta coherencia espacial, pero menor precisión por instancia.
5. **PointRend-Semántico**: rendimiento inferior en la mayoría de métricas.

Cabe destacar que estos patrones son coherentes con el conocimiento previo sobre el comportamiento de las CNNs, que tienden a explotar patrones texturales locales para la clasificación y segmentación. En el caso de *Juniperus*, donde las copas presentan una textura interna muy marcada, los modelos basados en instancias son capaces de aprovechar mejor estas señales locales y separar individuos próximos, mientras que los modelos puramente semánticos tienden a suavizar estas texturas y fusionar copas contiguas.

5.2 Resultados detallados por arquitectura

En esta sección se analizan de manera individual las cinco arquitecturas evaluadas según los criterios definidos en la Sección 4.4. Para cada modelo se describe la sensibilidad al umbral de puntuación (θ_{score}), las métricas globales por instancia en PI y FW, el rendimiento por clases de tamaño, la capacidad para estimar cobertura y densidad en FW y, finalmente, la coherencia espacial mediante pACC, mIoU y fwIoU. La comparación cualitativa conjunta de predicciones se presenta posteriormente en la Sección 5.5.

5.2.1 Mask R-CNN

Sensibilidad al umbral θ_{score}

La Figura 7 muestra la evolución del F1 para IoU y S-IoU en función de θ_{score} en PI y FW. En PI el rendimiento aumenta de forma casi monótona hasta estabilizarse en torno a $\theta_{\text{score}} = 0.90$, valor que se selecciona como óptimo ($\theta_{\text{PI}}^* = 0.90$) al maximizar el F1 basado en S-IoU@0.5. En FW la curva presenta un máximo más amplio alrededor de $\theta_{\text{score}} = 0.50$, de modo que se fija $\theta_{\text{FW}}^* = 0.50$ según el mismo criterio que para PI (maximiza F1 basado en S-IoU@0.5). Estos umbrales resultan encajar con trabajos previos sobre este conjunto de datos.




Figura 7: Evolución del F1 en función de θ_{score} para Mask R-CNN en PI (izquierda) y FW (derecha).

Métricas globales por instancia

La Tabla 7 resume las métricas a nivel de instancia para IoU y S-IoU en ambos conjuntos. En PI, Mask R-CNN alcanza un F1 de 88.36 % (S-IoU@0.5), con valores altos y equilibrados de precisión y recall, lo que indica una excelente segmentación en el escenario de entrenamiento y validación interna. En FW, el F1 desciende a 77.87 % (S-IoU@0.5), manteniendo un balance muy similar entre precisión (77.99 %) y recall (77.76 %). La caída de rendimiento entre PI y FW es moderada y compatible con el paso a una validación externa con mayor variabilidad espacial y espectral y con diferencias de distribución respecto a las escenas de entrenamiento.

Dataset	Métrica	Thr	TP	FP	FN	Precisión	Recall	F1
PI-test ($\theta = 0.90$)	IoU	0.50	568	78	122	87.93	82.32	85.03
PI-test ($\theta = 0.90$)	IoU	0.75	480	166	210	74.30	69.57	71.85
PI-test ($\theta = 0.90$)	S-IoU	0.50	577	69	83	89.32	87.42	88.36
PI-test ($\theta = 0.90$)	S-IoU	0.75	553	93	104	85.60	84.17	84.88
FW ($\theta = 0.50$)	IoU	0.50	1240	468	531	72.60	70.02	71.28
FW ($\theta = 0.50$)	IoU	0.75	810	898	961	47.42	45.74	46.57
FW ($\theta = 0.50$)	S-IoU	0.50	1332	376	381	77.99	77.76	77.87
FW ($\theta = 0.50$)	S-IoU	0.75	1152	556	500	67.45	69.73	68.57

Tabla 7: Métricas por instancia en PI y FW para Mask R-CNN.

Rendimiento por tamaño

La Figura 8 muestra el F1 por clases de tamaño. En PI, los valores superan el 90% en los tamaños L, XL y XXL, con un descenso progresivo hacia los tamaños más pequeños (XS y S). En FW se mantiene el mismo patrón, con F1 algo menores pero todavía superiores al 80% para L y XL. Los arbustos más pequeños (XS, S) constituyen la clase más desafiante, aunque el modelo conserva un rendimiento aceptable (F1 en torno a 55–75%). Estos resultados refuerzan la idea de que Mask R-CNN es especialmente eficaz para copas medianas y grandes, mientras que la resolución limita la detección de los ejemplares de menor tamaño.




Figura 8: F1 por bin de tamaño en PI (izquierda) y FW (derecha) para Mask R-CNN.

Estimación de cobertura y densidad en FW

La Figura 9 compara la cobertura y la densidad observadas frente a las predichas en FW. La correlación entre coberturas es alta ($r = 0.81$), con un RMSE de 6.62% y un sesgo muy reducido (MBE = -1.57%). En el caso de la densidad, tras la corrección basada en watershed, se obtiene una correlación muy elevada ($r = 0.96$) y un RMSE de 19.49 individuos/ha, con un MBE prácticamente nulo, lo que indica ausencia de sesgo sistemático en la estimación de densidad. Estos resultados indican que Mask R-CNN no solo detecta correctamente los arbustos individuales, sino que también proporciona estimaciones fiables de variables ecológicas agregadas.




Figura 9: Cobertura (izquierda) y densidad (derecha) observadas frente a predichas en FW para Mask R-CNN.

Métricas espaciales

Las métricas espaciales de la Tabla 8 muestran que el mIoU pasa de 0.90 en PI a 0.82 en FW, mientras que el fwIoU se mantiene por encima de 0.93 en ambos casos. La ligera disminución en FW es coherente con el cambio de dominio, pero la coherencia espacial global de las máscaras sigue siendo alta.

Split	pACC	mIoU	fwIoU
PI-test	0.99	0.90	0.98
FW	0.96	0.82	0.93

Tabla 8: Coherencia espacial en PI y FW para Mask R-CNN.

5.2.2 DeepLabV3+

Sensibilidad al umbral θ_{score}

En DeepLabV3+, la Figura 10 muestra un comportamiento distinto al de Mask R-CNN. En ambos conjuntos el F1 permanece relativamente estable para valores bajos de θ_{score} y alcanza un máximo marcado cercano a 0.75, tanto en PI como en FW. A partir de ese punto el rendimiento cae bruscamente, por lo que se selecciona $\theta^* = 0.75$ al maximizar el F1 basado en S-IoU@0.5 en ambos conjuntos.




Figura 10: Evolución del F1 con θ_{score} para DeepLabV3+ en PI (izquierda) y FW (derecha).

Métricas globales por instancia

La Tabla 9 muestra que en PI DeepLabV3+ alcanza un F1 de 88.34 % (S-IoU@0.5), comparable al de Mask R-CNN, aunque con mayor precisión y menor recall, lo que indica predicciones más conservadoras. Sin embargo, en FW el F1 se reduce a 70.19 %, evidenciando una mayor sensibilidad al cambio de dominio. Las métricas con IoU@0.5 muestran un F1 de 51.45 %, lo que sugiere que este modelo tiende a producir máscaras con peor solapamiento directo con el ground truth, pese a que la métrica S-IoU resulta más favorable.

Dataset	Métrica	Thr	TP	FP	FN	Precisión	Recall	F1
PI-test ($\theta = 0.75$)	IoU	0.50	433	63	257	87.30	62.75	73.02
PI-test ($\theta = 0.75$)	IoU	0.75	286	210	404	57.66	41.45	48.23
PI-test ($\theta = 0.75$)	S-IoU	0.50	462	34	88	93.15	84.00	88.34
PI-test ($\theta = 0.75$)	S-IoU	0.75	408	88	156	82.26	72.34	76.98
FW ($\theta = 0.75$)	IoU	0.50	699	247	1072	73.89	39.47	51.45
FW ($\theta = 0.75$)	IoU	0.75	346	600	1425	36.58	19.54	25.47
FW ($\theta = 0.75$)	S-IoU	0.50	824	122	578	87.10	58.77	70.19
FW ($\theta = 0.75$)	S-IoU	0.75	661	285	781	69.87	45.84	55.36

Tabla 9: Métricas por instancia para DeepLabV3+ en PI y FW.

Rendimiento por tamaño

La Figura 11 muestra que DeepLabV3+ presenta un descenso especialmente acusado en la clase XS, donde los F1 son sensiblemente inferiores a los de Mask R-CNN. En tamaños medios y grandes (M, L, XL) los resultados mejoran sustancialmente, con F1(S-IoU@0.5) en torno a 65–70 % para M y por encima de 75–80 % para L y XL. Esto sugiere que la arquitectura captura bien las masas de vegetación más extensas, pero tiene más dificultades para detectar pequeños arbustos aislados o parcialmente mezclados con el fondo.




Figura 11: F1 por tamaño para DeepLabV3+ en PI (izquierda) y FW (derecha).

Estimación de cobertura y densidad en FW

En FW, la estimación de cobertura con DeepLabV3+ es muy precisa ($r = 0.97$, $RMSE = 2.96\%$), con un sesgo prácticamente nulo ($MBE = -0.91\%$), tal y como se aprecia en la Figura 12. En densidad, la correlación es menor ($r = 0.87$) y el RMSE asciende a 40.10 individuos/ha, con tendencia a la sobreestimación (MBE positivo). En conjunto, el modelo reproduce muy bien la fracción de copa, pero tiende a agrupar o fusionar arbustos, lo que dificulta el conteo individual.




Figura 12: Scatterplots de la cobertura (izquierda) y densidad (derecha) observadas frente a predichas para DeepLabV3+ en FW.

Métricas espaciales

Las métricas de la Tabla 10 muestran que DeepLabV3+ alcanza el mayor mIoU en FW (0.83), ligeramente superior al de Mask R-CNN, lo que confirma la buena coherencia espacial de las máscaras generadas. El fwIoU también es elevado (0.94), reflejando un excelente ajuste global a nivel de píxel.

Split	pACC	mIoU	fwIoU
PI-test	0.99	0.90	0.97
FW	0.97	0.83	0.94

Tabla 10: Coherencia espacial para DeepLabV3+.

5.2.3 PointRend-Instancias

Sensibilidad al umbral

En PointRend-Instancias (Figura 13), el F1 aumenta progresivamente con θ_{score} en PI y FW, con máximos en torno a $\theta_{\text{PI}}^* = 0.90$ y $\theta_{\text{FW}}^* = 0.75$. El comportamiento es similar al de Mask R-CNN, aunque los valores máximos de F1 son ligeramente inferiores, especialmente en FW.




Figura 13: F1 frente a θ_{score} para PointRend-Instancias en PI (izquierda) y FW (derecha).

Métricas globales por instancia

La Tabla 11 muestra que en PI el modelo consigue F1 superiores al 85 % para S-IoU@0.5, con un recall muy elevado (91.59 %). En FW, el F1 se sitúa en 74.17 % (S-IoU@0.5), ligeramente por debajo de Mask R-CNN pero aún dentro de un rango alto. En líneas generales, PointRend-Instancias mantiene un buen equilibrio entre detección de instancias y precisión geométrica, con recall muy alto en PI y un equilibrio P/R más conservador en FW.

Dataset	Métrica	Thr	TP	FP	FN	Precisión	Recall	F1
PI-test ($\theta = 0.90$)	IoU	0.50	606	133	84	82.00	87.83	84.81
PI-test ($\theta = 0.90$)	IoU	0.75	499	240	191	67.52	72.32	69.84
PI-test ($\theta = 0.90$)	S-IoU	0.50	588	151	54	79.57	91.59	85.16
PI-test ($\theta = 0.90$)	S-IoU	0.75	508	231	103	68.74	83.14	75.26
FW ($\theta = 0.75$)	IoU	0.50	1275	518	496	71.11	71.99	71.55
FW ($\theta = 0.75$)	IoU	0.75	803	990	968	44.79	45.34	45.06
FW ($\theta = 0.75$)	S-IoU	0.50	1288	505	392	71.83	76.67	74.17
FW ($\theta = 0.75$)	S-IoU	0.75	984	809	560	54.88	63.73	58.98

Tabla 11: Métricas por instancia para PointRend-Instancias.

Rendimiento por tamaño

La Figura 14 muestra que PointRend-Instancias presenta muy buen rendimiento en tamaños medios y grandes (M, L, XL) tanto en PI como en FW, con F1(S-IoU) entre 75–85 %. En FW, la clase XXL sufre una ligera caída respecto a Mask R-CNN, lo que sugiere que el modelo puede fragmentar algunos arbustos de gran tamaño cuando la textura interna es muy heterogénea. En XS y S los resultados son similares a los de Mask R-CNN, confirmando que la principal dificultad reside en la detección de objetos pequeños, más que en la arquitectura concreta.




Figura 14: F1 por tamaño para PointRend-Instancias en PI (izquierda) y FW (derecha).

Estimación de cobertura y densidad en FW

La Figura 15 indica una correlación muy alta tanto en cobertura ($r = 0.94$, RMSE = 4.49 %) como en densidad ($r = 0.95$, RMSE = 27.56 ind/ha), con un sesgo moderado hacia la subestimación en ambos casos (MBE negativo). Por tanto, PointRend-Instancias proporciona estimaciones ecológicas precisas, aunque el RMSE en densidad es algo menor que el de Mask R-CNN.




Figura 15: Cobertura (izquierda) y densidad (derecha) observadas frente a predichas en FW para PointRend-Instancias.

Métricas espaciales

Las métricas espaciales de la Tabla 12 muestran un mIoU de 0.83 en FW, similar al de DeepLabV3+ y superior al de Mask R-CNN, lo que confirma la alta fidelidad espacial de las máscaras generadas por PointRend-Instancias.

Split	pACC	mIoU	fwIoU
PI-test	0.99	0.91	0.98
FW	0.97	0.83	0.94

Tabla 12: Coherencia espacial para PointRend-Instancias.

5.2.4 PointRend-Semántico

Sensibilidad al umbral

En PointRend-Semántico (Figura 16) las curvas de F1 muestran un máximo pronunciado alrededor de $\theta_{\text{score}} = 0.80$, tanto en PI como en FW. El comportamiento es más abrupto que en DeepLabV3+ e Instancias, mostrando mayor sensibilidad. Para valores superiores el F1 cae rápidamente debido a un exceso de filtrado de píxeles positivos, mientras que para valores inferiores el modelo genera demasiados falsos positivos, lo que indica una mayor sensibilidad del modelo a la elección del umbral.




Figura 16: F1 frente a θ_{score} para PointRend-Semántico en PI (izquierda) y FW (derecha).

Métricas globales por instancia

La Tabla 13 muestra que, aunque en PI el modelo alcanza F1 superiores al 90 % (S-IoU@0.5), en FW el F1 desciende a 67.49 %, el valor más bajo entre las arquitecturas evaluadas. El enfoque puramente semántico tiende a fusionar copas cercanas y a perder instancias individuales, lo que repercute directamente en el conteo de arbustos.

Dataset	Métrica	Thr	TP	FP	FN	Precisión	Recall	F1
PI-test ($\theta = 0.80$)	IoU	0.50	476	72	214	86.86	68.99	76.90
PI-test ($\theta = 0.80$)	IoU	0.75	368	180	322	67.15	53.33	59.45
PI-test ($\theta = 0.80$)	S-IoU	0.50	509	39	59	92.88	89.61	91.22
PI-test ($\theta = 0.80$)	S-IoU	0.75	477	71	92	87.04	83.83	85.41
FW ($\theta = 0.80$)	IoU	0.50	770	211	1001	78.49	43.48	55.96
FW ($\theta = 0.80$)	IoU	0.75	466	515	1305	47.50	26.31	33.87
FW ($\theta = 0.80$)	S-IoU	0.50	844	137	676	86.03	55.53	67.49
FW ($\theta = 0.80$)	S-IoU	0.75	689	292	856	70.23	44.60	54.55

Tabla 13: Métricas por instancia para PointRend-Semántico.

Rendimiento por tamaño

Como se aprecia en la Figura 17, PointRend-Semántico presenta F1 notablemente inferiores en las clases XS y S, y una caída marcada en XXL en FW, donde aparecen errores de fragmentación y confusión con manchas de sombra. En tamaños medios (M, L) el rendimiento mejora, pero sigue siendo inferior al de los modelos basados en instancias, lo que confirma que la arquitectura semántica tiene dificultades para representar adecuadamente copas individuales a distintas escalas.




Figura 17: F1 por tamaño para PointRend-Semántico en PI (izquierda) y FW (derecha).

Estimación de cobertura y densidad en FW

La Figura 18 muestra una buena correlación en cobertura ($r = 0.90$, $RMSE = 6.19\%$), pero la estimación de densidad presenta un RMSE elevado (49.34 ind/ha) y un sesgo claro hacia la sobreestimación. En consecuencia, el modelo reproduce razonablemente bien la superficie cubierta por *Juniperus*, pero no distingue adecuadamente las instancias individuales.




Figura 18: Cobertura (izquierda) y densidad (derecha) observadas frente a predichas para PointRend-Semántico en FW.

Métricas espaciales

La Tabla 14 muestra que, aunque el mIoU en PI es alto (0.91), en FW disminuye a 0.79, el valor más bajo entre las arquitecturas analizadas. El fwIoU también se reduce, si bien se mantiene en valores altos. Este comportamiento confirma la menor robustez del modelo frente al cambio de dominio.

Split	pACC	mIoU	fwIoU
PI-test	0.99	0.91	0.98
FW	0.96	0.79	0.93

Tabla 14: Coherencia espacial para PointRend-Semántico.

5.2.5 Panoptic FPN

Sensibilidad al umbral

En Panoptic FPN (Figura 19) el F1 aumenta con θ_{score} hasta alcanzar un máximo alrededor de $\theta_{\text{PI}}^* = 0.85$ en PI y $\theta_{\text{FW}}^* = 0.60$ en FW. Las curvas presentan un plateau relativamente amplio alrededor del máximo, lo que indica cierta robustez frente a pequeñas variaciones del umbral.




Figura 19: F1 frente a θ_{score} para Panoptic FPN en PI (izquierda) y FW (derecha).

Métricas globales por instancia

La Tabla 15 muestra que en PI Panoptic FPN obtiene F1 cercanos al 87.43 % (S-IoU@0.5), ligeramente por debajo de Mask R-CNN pero dentro del rango alto. En FW el F1 para S-IoU@0.5 es 72.66 %, lo que sitúa al modelo en una posición intermedia entre Mask R-CNN/PointRend-Instancias y DeepLabV3+. El equilibrio entre precisión y recall es razonable, sin sesgos extremos hacia falsos positivos o falsos negativos.

Dataset	Métrica	Thr	TP	FP	FN	Precisión	Recall	F1
PI-test ($\theta = 0.85$)	IoU	0.50	586	108	104	84.44	84.93	84.68
PI-test ($\theta = 0.85$)	IoU	0.75	494	200	196	71.18	71.59	71.39
PI-test ($\theta = 0.85$)	S-IoU	0.50	588	106	63	84.73	90.32	87.43
PI-test ($\theta = 0.85$)	S-IoU	0.75	547	147	94	78.82	85.34	81.95
FW ($\theta = 0.60$)	IoU	0.50	1147	400	624	74.14	64.76	69.14
FW ($\theta = 0.60$)	IoU	0.75	758	789	1013	49.00	42.80	45.69
FW ($\theta = 0.60$)	S-IoU	0.50	1156	391	479	74.73	70.70	72.66
FW ($\theta = 0.60$)	S-IoU	0.75	973	574	630	62.90	60.70	61.78

Tabla 15: Métricas por instancia para Panoptic FPN en PI y FW.

Rendimiento por tamaño

La Figura 20 muestra un patrón similar al observado en otros modelos: menor rendimiento en XS, mejora progresiva hacia los tamaños medios y grandes y ligeras caídas en XXL. En FW, Panoptic FPN mantiene F1 altos (por encima del 75 %) en L y XL, si bien se sitúa ligeramente por detrás de Mask R-CNN y PointRend-Instancias en el promedio global. Esto refuerza su carácter de solución intermedia y estable.




Figura 20: F1 por tamaño para Panoptic FPN en PI (izquierda) y FW (derecha).

Estimación de cobertura y densidad en FW

La Figura 21 evidencia una buena capacidad de Panoptic FPN para reproducir tanto la cobertura ($r = 0.91$, $RMSE = 5.45$ %) como la densidad ($r = 0.94$, $RMSE = 25.36$ ind/ha), con sesgos muy reducidos. En términos de error, sus resultados se sitúan entre los de Mask R-CNN y PointRend-Instancias, reforzando su papel como modelo intermedio en rendimiento ecológico.




Figura 21: Cobertura (izquierda) y densidad (derecha) observadas frente a predichas para Panoptic FPN en FW.

Métricas espaciales

Finalmente, la Tabla 16 muestra que Panoptic FPN alcanza un mIoU de 0.81 y un fwIoU de 0.94 en FW, valores inferiores a los de DeepLabV3+ y PointRend-Instancias, pero superiores a los de PointRend-Semántico. En conjunto, se confirma como una solución equilibrada: no es el mejor modelo en ninguna métrica concreta, pero tampoco el peor en ninguna de ellas.

Split	pACC	mIoU	fwIoU
PI-test	0.99	0.89	0.97
FW	0.95	0.81	0.94

Tabla 16: Coherencia espacial para Panoptic FPN.

5.3 Comparación entre PI y FW

La comparación entre los resultados obtenidos en PI (entrenamiento y validación interna) y en FW (evaluación externa) permite cuantificar la capacidad de generalización de las distintas arquitecturas ante un cambio de dominio. En todos los modelos se observa una disminución del rendimiento al pasar de PI a FW, pero la magnitud de esta caída y su impacto en las métricas difieren según el enfoque de segmentación.

En primer lugar, las arquitecturas basadas en instancias (Mask R-CNN y PointRend-Instancias) muestran la transición más estable. Sus F1 (S-IoU@0.5) pasan de valores en torno al 85–88 % en PI a 74–78 % en FW, lo que supone una reducción moderada, coherente con el aumento de heterogeneidad espacial y espectral del conjunto externo. El mIoU también disminuye (de aproximadamente 0.90 en PI a 0.82 en FW), pero se mantiene en rangos elevados, indicando que la forma y posición de las máscaras continúan siendo coherentes pese al cambio de contexto.

En segundo lugar, Panoptic FPN presenta un comportamiento intermedio. En PI alcanza F1 y mIoU muy próximos a los de Mask R-CNN, y en FW la degradación es algo mayor, situándose ligeramente por debajo de los modelos de instancias en F1 pero por encima de DeepLabV3+ y PointRend-Semántico. Este patrón respalda la idea de que Panoptic FPN hereda parte de la robustez de los modelos de instancias, pero con una componente semántica que le hace algo más sensible al cambio de dominio.

En tercer lugar, las arquitecturas puramente semánticas (DeepLabV3+ y PointRend-Semántico) son las que sufren una reducción más acusada al pasar de PI a FW. Aunque en PI sus F1 bajo S-IoU@0.5 son comparables, o incluso superiores, a los de Mask R-CNN, en FW los F1 descienden hasta valores en torno al 70 % en el caso de DeepLabV3+ y por debajo del 70 % para PointRend-Semántico. Así mismo, el mIoU cae desde aproximadamente 0.90 en PI hasta 0.83 (DeepLabV3+) y 0.79 (PointRend-Semántico) en FW. Este comportamiento indica que la segmentación semántica es más sensible a variaciones en textura, iluminación y composición del paisaje, lo que se traduce en fusiones o pérdidas de copas individuales cuando se aplica fuera del dominio de entrenamiento.

En definitiva, estos resultados ponen de manifiesto que el cambio de PI a FW no afecta por igual a todas las arquitecturas. Los modelos de instancias muestran una mayor capacidad de generalización, manteniendo un buen compromiso entre precisión individual y coherencia espacial, mientras que los modelos semánticos acusan más intensamente el salto de dominio, especialmente en términos de detección y conteo de individuos.

5.4 Efecto del umbral de puntuación y del posprocesado

Además de las diferencias inherentes entre arquitecturas, el rendimiento final del sistema depende de las decisiones de posprocesado, en particular de la elección del umbral de puntuación (θ_{score}) y de la corrección aplicada en el cálculo de la densidad.

En primer lugar, el análisis de las curvas $F1-\theta_{\text{score}}$ revela patrones consistentes pero diferenciados entre modelos. Las arquitecturas de instancias (Mask R-CNN y PointRend-Instancias) presentan óptimos relativamente altos en PI ($\theta_{\text{PI}}^* \approx 0.90$) y más bajos en FW, reflejando que sus puntuaciones de confianza son más fiables en el dominio de entrenamiento y requieren umbrales más conservadores en el dominio externo. Sin embargo, DeepLabV3+ y PointRend-Semántico alcanzan sus máximos alrededor de $\theta^* \in [0.70, 0.80]$, con curvas más pronunciadas, lo que indica una mayor sensibilidad a la elección del umbral: pequeños cambios en θ_{score} pueden traducirse en variaciones importantes de F1 por un balance distinto entre falsos positivos y falsos negativos.

Este comportamiento tiene implicaciones directas para la operatividad del sistema. Los modelos con mesetas amplias alrededor del máximo (como Mask R-CNN y Panoptic FPN) resultan más robustos frente a ajustes de umbral subóptimos, mientras que los modelos con máximos muy estrechos (especialmente PointRend-Semántico) requieren una calibración más cuidadosa para evitar degradaciones bruscas del rendimiento.

En segundo lugar, el posprocesado aplicado a las métricas ecológicas, en particular la corrección mediante watershed en la estimación de densidad, tiene un efecto notable. En cobertura, las diferencias entre la versión base y la versión ajustada son prácticamente despreciables: el RMSE y el R^2 se mantienen invariantes o varían mínimamente, lo que indica que el cálculo directo de la fracción de copa ya es suficientemente robusto. Sin embargo, en densidad y densidad por hectárea, la corrección mejora de forma sustancial las métricas, reduciendo el RMSE y aumentando el R^2 hasta valores próximos a 0.9 en los modelos más fiables.

Esta mejora se explica por la naturaleza discreta de la densidad, que amplifica los errores de sobre- y subdetección de instancias individuales. El watershed actúa como un ajuste global que corrige sistemáticamente los sesgos del conteo bruto, alineando mejor las estimaciones con los patrones observados. En consecuencia, el posprocesado no altera la jerarquía relativa entre modelos, pero sí refuerza la utilidad práctica de las predicciones al mejorar de forma clara la coherencia de las métricas ecológicas derivadas.

5.5 Análisis cualitativo de las predicciones

En esta sección, se analizan de forma cualitativa las predicciones de las cinco arquitecturas para varias escenas representativas. El objetivo es complementar las métricas cuantitativas con ejemplos visuales que ayuden a entender dónde y cómo se producen los aciertos y errores de cada modelo, tanto en el conjunto interno (PI) como en la evaluación externa (FW).

5.5.1 Ejemplificación de predicciones en PI y FW

Comparación visual entre modelos en PI

En la Figura 22 se muestra una escena relativamente sencilla del conjunto PI, en la que aparecen siete copas de *Juniperus* bien definidas y alineadas siguiendo una zona de cambio de pendiente. La máscara de referencia (GT) contiene, por tanto, 7 instancias separadas entre sí y con un contraste moderado respecto al fondo.

En esta escena, todas las arquitecturas capturan adecuadamente la mayoría de los arbustos y las diferencias se concentran en el grado de sobre- o subdetección y en pequeños detalles de contorno:

- Mask R-CNN detecta las 7 instancias presentes en el GT y reproduce formas muy similares, con contornos ajustados y sin apenas pérdida de área.
- DeepLabV3+ subdetecta la escena con 6 instancias: una de las copas pequeñas desaparece. Las máscaras son limpias y continuas, pero la arquitectura tiende a eliminar objetos de tamaño reducido o con menor contraste local.
- PointRend-Instancias se comporta de forma muy parecida a Mask R-CNN, recuperando también las 7 copas. El refinamiento adaptativo en el borde permite contornos algo más afinados y una buena separación entre copas cercanas.
- PointRend-Semántico detecta igualmente 7 copas, aunque con bordes algo más suavizados. Se aprecia cierta tendencia a redondear las copas y a simplificar irregularidades finas, pero sin fusionar arbustos distintos.
- Panoptic FPN detecta 8 instancias, es decir, una más que el GT. Esta sobre-detección se debe a la fragmentación de una copa en dos regiones separadas, reflejando cierta propensión de la arquitectura panóptica a dividir objetos alargados o con variaciones internas de textura.




Figura 22: Ejemplo cualitativo de las predicciones que hacen los modelos para una imagen del conjunto PI. Imagen original con GT (arriba izquierda) y predicciones de los cinco modelos. Se indica el número de instancias detectadas por cada arquitectura.

La Figura 23 presenta un segundo ejemplo en PI con mayor complejidad. En este caso el GT contiene 13 arbustos, muchos de ellos de tamaño pequeño y situados en un entorno de textura más rugosa y heterogénea, lo que dificulta distinguir las copas del fondo rocoso.




Figura 23: Ejemplo cualitativo de máscaras predichas por los cinco modelos para una imagen del dataset PI. Se muestra una escena con varios arbustos de tamaño pequeño y medio en un terreno de textura heterogénea.

En este escenario las diferencias entre arquitecturas son mucho más marcadas:

- Mask R-CNN detecta 5 arbustos, concentrando sus aciertos en las copas de mayor tamaño y contraste. La mayoría de los arbustos pequeños desaparecen, lo que indica una pérdida de sensibilidad frente a objetos diminutos.
- DeepLabV3+ detecta 6 instancias. Aunque mejora ligeramente el conteo respecto a Mask R-CNN, sigue perdiendo una parte importante de las copas pequeñas y tiende a generar máscaras relativamente compactas, que a veces integran varias copas cercanas en una única región.
- PointRend-Instancias detecta 10 arbustos, siendo el modelo que mejor se aproxima al conteo real en esta escena. Captura una fracción notablemente mayor de copas pequeñas y mantiene una separación razonable entre ellas, aunque todavía fusiona algunos arbustos muy próximos.
- PointRend-Semántico detecta 5 copas, un comportamiento similar al de Mask R-CNN en términos de conteo. La segmentación es estable en las copas grandes, pero se pierden muchas instancias pequeñas o de bajo relieve.
- Panoptic FPN detecta 6 arbustos. De nuevo, las copas grandes se reproducen con precisión, pero la arquitectura panóptica tiende a fusionar o ignorar arbustos pequeños y a priorizar regiones continuas de mayor tamaño.

Este segundo ejemplo en PI pone de manifiesto que, en escenas con varios arbustos pequeños y fondo heterogéneo, la diferencia entre modelos se acentúa. El enfoque con refinamiento puntual de PointRend-Instancias es el que mejor preserva el conteo y la

individualización de copas pequeñas, mientras que el resto de arquitecturas (tanto de instancias como semánticas y panópticas) tienden a perder objetos de bajo tamaño o a fusionar varias copas en una sola región.

En general, los ejemplos de PI muestran que no existe un modelo claramente superior en todos los casos, pero sí patrones consistentes: en escenas simples, todas las arquitecturas reproducen adecuadamente la estructura general del GT, aunque los modelos de instancias (Mask R-CNN y PointRend-Instancias) mantienen una ligera ventaja en la separación de objetos adyacentes. En escenas más complejas, la capacidad para detectar arbustos pequeños y mantener la separación entre copas constituye el principal factor diferenciador, siendo PointRend-Instancias el modelo que mejor conserva el conteo en el conjunto PI.

Comparación visual entre modelos en FW

Las Figuras 24 y 25 muestran ejemplos análogos en el conjunto FW, donde los efectos del cambio de dominio respecto a PI (textura, iluminación y distribución espacial de las copas) son más evidentes.

En la Figura 24 se presenta un caso sencillo, en el que aparece una escena con un único arbusto claramente visible en el borde izquierdo de la imagen. El GT contiene, por tanto, una única copa compacta y bien delimitada.

En este contexto, los modelos muestran comportamientos diferenciados:

- Mask R-CNN detecta correctamente la única instancia, reproduciendo una máscara de tamaño y forma similares a las del GT.
- DeepLabV3+ detecta correctamente la copa presente en la imagen, pero además detecta una masa en el borde derecho (semejante a una laguna) como arbusto.
- PointRend-Instancias reproduce correctamente la detección única, sin sobresegmentación apreciable.
- PointRend-Semántico no detecta ninguna instancia, lo que supone una pérdida completa del objeto en esta escena sencilla.
- Panoptic FPN detecta un arbusto en el centro inferior de la imagen, el cual no corresponde con la instancia real, por lo que este modelo falla completamente en este ejemplo.

Este ejemplo evidencia que, incluso en una situación simple y con una única copa, el cambio de dominio puede provocar comportamientos inestables como la detección de objetos que no son *Juniperus* (DeepLabV3+, Panoptic FPN) o la desaparición de instancias (PointRend-Semántico), mientras que los métodos basados en instancias mantienen una segmentación más estable.




Figura 24: Ejemplo cualitativo de una predicción realizada por cada modelo para una imagen del dataset FW. Se trata de una escena sencilla con un único arbusto situado en el borde de la imagen.

En contraposición, la Figura 25 muestra una región mucho más densa y heterogénea, con 105 arbustos en el GT formando bandas y masas complejas de copas muy próximas entre sí. Se trata de un ejemplo de alta dificultad, donde los cambios de iluminación y textura del dominio FW amplifican los errores de fusión y pérdida de objetos.

Los modelos presentan aquí comportamientos claramente divergentes:

- Mask R-CNN detecta 78 instancias, reproduciendo relativamente bien la estructura general, pero con una fusión notable de copas contiguas en las zonas más densas, lo que conduce a una subestimación del conteo.
- DeepLabV3+ detecta tan solo 38 arbustos. Las máscaras son muy continuas y suavizadas, integrando grandes grupos de copas en regiones extensas y perdiendo gran parte de las separaciones finas.
- PointRend-Instancias detecta 69 instancias, con un patrón similar al de Mask R-CNN, aunque con una ligera mayor tendencia a fusionar copas pequeñas o parcialmente ocultas.
- PointRend-Semántico detecta 66 arbustos. A pesar de mejorar el conteo respecto a DeepLabV3+, sigue mostrando una fuerte tendencia a combinar varias copas en masas más grandes y homogéneas.
- Panoptic FPN detecta 85 instancias y es el modelo que más se aproxima al conteo real en esta escena. No obstante, también presenta fusiones importantes en las zonas de mayor densidad, por lo que sigue infraestimando el número de arbustos.




Figura 25: Ejemplo cualitativo de predicciones de los cinco modelos para una imagen del dataset FW con alta densidad de arbustos. La proximidad entre copas favorece la fusión de instancias y la pérdida de separaciones finas.

Este ejemplo confirma que, en regiones dominadas por copas muy numerosas y próximas entre sí, la dificultad principal reside en mantener un equilibrio adecuado entre fragmentación y fusión. En FW, todos los modelos tienden a subestimar el conteo por fusión de copas, siendo Panoptic FPN el que mejor se aproxima al número real de arbustos, seguido de Mask R-CNN y PointRend-Instancias. Los enfoques semánticos (DeepLabV3+ y PointRend-Semántico) priorizan la coherencia espacial de grandes masas, pero a costa de una pérdida de separaciones finas y, por tanto, de una fuerte infraestimación del número de arbustos.

En definitiva, los resultados cualitativos en FW sugieren que el rendimiento está fuertemente condicionado por el cambio de textura, iluminación y patrón espacial respecto al dominio PI. En escenas simples, algunos modelos semánticos pueden fallar incluso en la detección de una única copa, mientras que en escenas densas todos los modelos muestran dificultades para preservar la individualización de copas. Los modelos basados en instancias (Mask R-CNN y PointRend-Instancias) y el modelo panóptico (Panoptic FPN) mantienen un comportamiento relativamente más estable que los enfoques puramente semánticos, aunque continúan infraestimando el conteo en regiones de alta densidad arbustiva.

5.5.2 Tipología de errores

Para analizar con mayor detalle los errores sistemáticos, se seleccionaron dos regiones problemáticas (*hotspots*) dentro de la misma imagen perteneciente al conjunto FW, mostradas en las Figuras 26 y 27. En cada una se presentan, de nuevo, la imagen original con la GT y las predicciones de las cinco arquitecturas.

En la Figura 26 se muestra una zona con varias copas grandes y medias muy próximas

entre sí, lo que genera un escenario propenso tanto a la fusión como a la fragmentación. En el GT se observan copas bien definidas, aunque con formas irregulares y bordes complejos debido a la textura del fondo.

En este hotspot, los modelos de instancias (Mask R-CNN y PointRend-Instancias) tienden a fusionar copas extensas en múltiples partes, especialmente cuando las irregularidades de borde presentan fuertes cambios locales (para PointRend-Instancias, fusiona y realiza una detección parcial de las copas). Del mismo modo ocurre con DeepLabV3+ y Panoptic FPN, ya que ambos fusionan copas contiguas en masas arbustivas amplias, perdiendo separaciones finas. PointRend-Semántico combina ambos efectos, ya que logra capturar algunas copas completas, pero también fragmenta regiones de densidad alta y pierde detalle en pequeñas discontinuidades. Este patrón refleja las dificultades de todas las arquitecturas para mantener simultáneamente coherencia espacial y separación entre copas cercanas.




Figura 26: Hotspot 1 (conjunto FW): copas grandes y próximas. Se aprecia la fragmentación de copas extensas en los modelos de instancias y la fusión de masas arbustivas en arquitecturas con enfoque más semántico.

La Figura 27 muestra una región con copas medianas y pequeñas distribuidas alrededor de una pista que atraviesa el hotspot. Esta mezcla de discontinuidad lineal (la pista) y copas de tamaño variable introduce dificultades adicionales para la segmentación.

En este caso, DeepLabV3+ y Panoptic FPN presentan errores de fusión a lo largo del trazado de la pista, incorporando parte del camino dentro de las masas segmentadas o uniendo copas que deberían estar separadas. Por su parte, PointRend-Semántico produce sobresegmentación en los bordes arbustivos, dando lugar a fragmentos pequeños y contornos irregulares. Los modelos de instancias (sobre todo Mask R-CNN) fusionan copas medianas, especialmente cuando la textura del fondo introduce ruido que altera la división de las copas en el GT.




Figura 27: Hotspot 2 (conjunto FW): copas medianas y pequeñas atravesadas por una pista. Aparecen errores de fusión a lo largo del camino y fragmentación en bordes de copa según la arquitectura.

Estos ejemplos permiten identificar cuatro tipos de errores recurrentes:

- Subdetección de arbustos pequeños o aislados, especialmente en Mask R-CNN y Panoptic FPN en el conjunto FW.
- Sobresegmentación y fragmentación de copas grandes, más frecuente en PointRend-Semántico y, en menor medida, en los modelos de instancias.
- Fusión de copas contiguas, característica de DeepLabV3+ y Panoptic FPN en zonas densamente pobladas o en presencia de texturas complejas.
- Falsos positivos en estructuras lineales o sombras, observados principalmente en DeepLabV3+ y PointRend-Sem en regiones atravesadas por pistas o cambios bruscos de textura.

5.5.3 Síntesis cualitativa: fortalezas y debilidades

El análisis cualitativo realizado sobre los ejemplos de PI y FW, junto con el estudio detallado de los hotspots, permite caracterizar con claridad las fortalezas y limitaciones de cada arquitectura en el contexto de la detección individual de arbustos *Juniperus*. En primer lugar, los modelos de instancias (Mask R-CNN y PointRend-Instancias) son los que muestran el comportamiento más estable y coherente en ambos dominios. En escenas simples o moderadamente densas, preservan de forma fiable la individualidad de las copas y reproducen contornos ajustados. Mask R-CNN mantiene un equilibrio notable entre precisión espacial y separación entre arbustos, mientras que PointRend-Instancias mejora la detección de copas pequeñas y afina los bordes gracias a su refinamiento adaptativo.

No obstante, ambos modelos tienden a fragmentar copas grandes en zonas con bordes muy irregulares o alta variabilidad local, como se aprecia en los hotspots.

Los modelos con un componente más semántico presentan patrones complementarios, pero con limitaciones más marcadas. DeepLabV3+ genera máscaras suaves, coherentes y continuas, lo que explica su buen rendimiento cuando se evalúan métricas basadas en área. Sin embargo, esta coherencia espacial se traduce en una fuerte tendencia a fusionar copas próximas, especialmente en regiones de alta densidad, y a incorporar estructuras lineales o sombras como parte de las masas vegetales. Panoptic FPN muestra un comportamiento intermedio: sus segmentaciones son estructuralmente consistentes, pero el conteo de instancias es sistemáticamente más conservador, con pérdidas de arbustos pequeños y fusiones en áreas densas. Por su parte, PointRend-Semántico resulta ser el modelo más variable: en algunas escenas reproduce copas con gran detalle, mientras que en otras tiende a la fragmentación excesiva o directamente a la desaparición de objetos pequeños, especialmente en el dominio FW.

Estas observaciones permiten identificar cuatro errores recurrentes: (i) la subdetección de arbustos pequeños, predominante en Mask R-CNN, Panoptic FPN y PointRend-Semántico; (ii) la fragmentación de copas grandes, característica de PointRend-Semántico y, en menor medida, de los modelos de instancias; (iii) la fusión de copas adyacentes, habitual en DeepLabV3+ y Panoptic FPN; y (iv) los falsos positivos asociados a estructuras lineales o texturas alargadas, más comunes en DeepLabV3+ y PointRend-Semántico.

En definitiva, los resultados cualitativos refuerzan que, para el objetivo del estudio —la detección individual de arbustos—, las arquitecturas basadas en instancias constituyen la opción más adecuada, al ser las que mejor conservan la separación entre copas y mantienen un comportamiento más robusto ante cambios de dominio. Por el contrario, los enfoques puramente semánticos resultan más apropiados cuando el interés se centra en la delimitación continua de la vegetación, pero no en la identificación de cada arbusto individual.

5.6 Interpretación ecológica de los resultados

Más allá del rendimiento numérico de las arquitecturas, es relevante valorar hasta qué punto las predicciones obtenidas son útiles desde una perspectiva ecológica y de gestión. En este trabajo se han considerado dos indicadores derivados clave: la cobertura de copa de *Juniperus* y la densidad de individuos por unidad de superficie. Ambos están directamente relacionados con el estado del matorral, la competencia por recursos y la estructura del hábitat.

En primer lugar, los resultados de cobertura muestran que todas las arquitecturas son capaces de reproducir con buena precisión la fracción de copa a escala de parcela, especialmente Mask R-CNN, DeepLabV3+ y PointRend-Instancias. En estos modelos, los errores relativos medios (RMSE) se sitúan por debajo del 7 % y los coeficientes de determinación (R^2) son elevados, lo que indica que la distribución espacial global de la vegetación está bien capturada. Desde un punto de vista ecológico, esto significa que las imágenes segmentadas permiten diferenciar de forma fiable entre zonas densamente cubiertas por matorral y áreas más abiertas, aspecto fundamental para la evaluación del estado de conservación, la planificación de actuaciones de gestión o la delimitación de gradientes de densificación.

En segundo lugar, las métricas de densidad son más exigentes, ya que dependen de la correcta identificación y conteo de individuos. En este caso las diferencias entre arquitecturas son más acusadas. Mask R-CNN y PointRend-Instancias proporcionan las

estimaciones más consistentes, con errores moderados y R^2 elevados tras la corrección mediante watershed. Panoptic FPN se sitúa en una posición intermedia, mientras que DeepLabV3+ y, sobre todo, PointRend-Semántico tienden a sobreestimar la densidad en zonas de matorral denso, donde varios arbustos se fusionan visualmente.

Desde el punto de vista ecológico, estas diferencias tienen implicaciones directas. La subestimación sistemática de densidad puede conducir a infravalorar el grado de ocupación del hábitat y la intensidad de la competencia intraespecífica, mientras que la sobreestimación puede exagerar la aparente saturación del espacio y enmascarar procesos de regeneración o mortalidad. En este sentido, las arquitecturas de instancias se muestran más adecuadas cuando el objetivo principal es cuantificar el número de individuos o analizar patrones de agregación y dispersión.

Por último, la combinación de buenas métricas de cobertura y densidad sugiere que los mejores modelos (principalmente Mask R-CNN y PointRend-Instancias) son capaces de representar tanto la cantidad total de vegetación como su organización en unidades discretas. Esto abre la puerta a aplicaciones ecológicas de mayor nivel, como el estudio de la estructura de tamaños, la detección de focos de expansión o retracción del matorral y la evaluación de escenarios de cambio en el contexto de la gestión de hábitats de alta montaña.

5.7 Limitaciones del estudio

Aunque los resultados obtenidos son prometedores, conviene señalar varias limitaciones que condicionan su interpretación y la extrapolación de las conclusiones.

En primer lugar, el análisis se ha realizado sobre un número limitado de escenas y en una región concreta de Sierra Nevada, bajo unas condiciones de iluminación, fenología y resolución espacial específicas. Aunque el conjunto FW actúa como evaluación externa, sigue perteneciendo al mismo ámbito geográfico y tipo de paisaje, por lo que la generalización a otras áreas, especies acompañantes o condiciones climáticas debe abordarse con cautela.

En segundo lugar, la anotación de las copas de *Juniperus* presenta una complejidad intrínseca asociada al fuerte polimorfismo de la especie, la presencia de sombras proyectadas y la transición gradual entre copa y fondo. Incluso en el ground truth, pueden existir incertidumbres en la delimitación exacta de los individuos, especialmente en masas densas o en copas parcialmente solapadas. Esto implica que las métricas basadas en IoU o S-IoU están sujetas a un cierto margen de error de referencia.

En tercer lugar, todas las arquitecturas se han entrenado y evaluado bajo un conjunto de hiperparámetros y configuraciones relativamente acotado, con un número fijo de iteraciones y sin explorar de forma exhaustiva estrategias avanzadas de data augmentation o combinaciones de modelos. Es posible que ajustes adicionales, arquitecturas alternativas de backbone o técnicas específicas de calibración de scores mejorasen todavía más el rendimiento de algunos modelos, en particular los de segmentación semántica.

En cuarto lugar, las métricas ecológicas de densidad dependen de un paso de posprocesado que traduce máscaras en conteos de individuos. Aunque el watershed implementado reduce de forma importante los sesgos globales, sigue existiendo incertidumbre a nivel de parcela, especialmente en áreas con copas muy agregadas o de geometría irregular. Este aspecto debe tenerse en cuenta al utilizar los mapas derivados para análisis finos de estructura poblacional.

Finalmente, el estudio se ha centrado en una única especie dominante de matorral. La presencia de otras especies arbustivas o arbóreas con morfologías y firmas espectrales

similares podría introducir confusiones adicionales en contextos más diversos. La extensión del enfoque a paisajes más complejos requeriría incorporar información adicional (por ejemplo, datos multitemporales o de otros sensores) y validar de nuevo las arquitecturas seleccionadas.

A pesar de estas limitaciones, los resultados obtenidos proporcionan una base sólida para el uso de modelos de segmentación profunda en la detección y caracterización de matorrales de *Juniperus* a partir de imágenes satelitales, y señalan claramente qué arquitecturas son más prometedoras para su aplicación en contextos reales de gestión.

6 Conclusiones

El presente trabajo ha evaluado de manera exhaustiva diversas arquitecturas de segmentación profunda aplicadas a la detección individual de arbustos del género *Juniperus* en imágenes satelitales de alta resolución. Para ello, se han utilizado dos conjuntos de datos complementarios; por un lado, el conjunto PI, empleado para entrenamiento, validación y evaluación interna, y, por otro lado, el conjunto FW, diseñado como evaluación externa y, por tanto, utilizado como medida realista de la capacidad de generalización de los modelos. Las métricas analizadas abarcan tanto la precisión por instancia (IoU y S-IoU), como la coherencia espacial (mIoU), el comportamiento por clases de tamaño y la estimación de variables ecológicas derivadas (cobertura y densidad).

Un aspecto clave que ha guiado la interpretación de los resultados es el conocido sesgo a la textura de las arquitecturas convolucionales. Las copas de *Juniperus* presentan una textura muy característica, con patrones rugosos, microcontrastes internos y bordes irregulares bien definidos, lo que constituye una firma visual particularmente informativa para modelos basados en CNN. Esta propiedad ha influido de forma decisiva en qué arquitecturas han destacado y cuáles han mostrado mayores limitaciones en la detección individual.

A partir de los resultados obtenidos, se pueden extraer las siguientes conclusiones principales:

Conclusiones técnicas

1. **Mask R-CNN** es la arquitectura con mejor rendimiento global. El modelo obtiene el mayor F1 basado en S-IoU@0.5 en FW (77.87 %), la mayor estabilidad entre PI y FW y los mejores resultados en la estimación de densidad ($R^2 = 0.91$), demostrando una capacidad sobresaliente para detectar instancias individuales de *Juniperus*.
2. **PointRend-Instancias**, modelo basado en renderizado incremental, también presenta un rendimiento elevado. Este modelo destaca especialmente en coherencia espacial (mIoU = 0.83 en FW), manteniendo un buen equilibrio entre segmentación precisa y máscaras suaves. Su rendimiento está estrechamente relacionado con su mecanismo de refinamiento: PointRend selecciona puntos de alta incertidumbre en los bordes y los reclasifica utilizando información local de alta frecuencia, precisamente el tipo de señal textural que define las copas de *Juniperus*. De este modo, logra una delineación fina de los contornos y una precisión notable en tamaños medianos y grandes.
3. **DeepLabV3+** ofrece las máscaras más coherentes espacialmente, pero con menor precisión por instancia. Aunque obtiene el mayor mIoU junto con PointRend-Instancias (mIoU = 0.83), su F1 en FW es notablemente inferior (70.19 %), lo que indica una tendencia a fusionar copas contiguas y dificultar el conteo individual. Esto se debe, en

parte, a que esta arquitectura integra la información en escalas amplias mediante módulos ASPP, suavizando los patrones locales y, por tanto, diluyendo la textura fina que caracteriza a los arbustos individuales.

4. **PointRend-Semántico** resulta ser el modelo menos adecuado para detectar individuos. Su debilidad aparece de forma consistente en todas las métricas: menor F1, menor mIoU y mayores errores en densidad. La razón principal es que la aproximación puramente semántica tiende a homogenizar regiones continuas y a ignorar los detalles texturales locales que permitirían separar copas cercanas o distinguir *Juniperus* de sombras u otros objetos.
5. **Panoptic FPN** actúa como solución intermedia. No destaca como el mejor modelo en ninguna métrica, pero mantiene un rendimiento estable en todas ellas, ofreciendo un equilibrio razonable entre segmentación semántica e identificación de instancias. No obstante, su mayor coste computacional y su menor sensibilidad a la textura local en comparación con los modelos estrictamente de instancias limitan su rendimiento en escenarios complejos.
6. La sensibilidad al umbral θ_{score} es arquitecturalmente dependiente. Mask R-CNN y PointRend-Instancias requieren valores altos y más estrictos (entre 0.75 y 0.90), mientras que DeepLabV3+ y Panoptic FPN presentan máximos en intervalos más amplios y estables. La selección correcta del umbral es crítica para evitar sesgos en falsos positivos o negativos.
7. El rendimiento disminuye de forma sistemática en los arbustos más pequeños (XS y S). En todas las arquitecturas aparece el mismo patrón: F1 bajo en XS/S y mejora progresivamente hacia M, L y XL, aunque vuelve a disminuir en copas XXL. Este comportamiento se explica por limitaciones ligadas a la resolución espacial y por la menor expresividad textural de las copas más pequeñas, mientras que para las copas grandes suele ocurrir una detección parcial y no completa de toda la corona arbustiva.

Conclusiones ecológicas y aplicadas

1. La cobertura se estima con muy alta precisión en los mejores modelos. Mask R-CNN, DeepLabV3+ y PointRend-Instancias presentan RMSE entre 2.9 % y 6.6 %, lo que permite mapear con fiabilidad la fracción de copa a escala de paisaje. Esto convierte a los modelos en herramientas válidas para estudios de estado del hábitat, planificación ambiental y análisis de cambios en el tiempo.
2. La estimación de densidad depende fuertemente de la calidad de la detección individual. Los modelos de instancias (Mask R-CNN y PointRend-Instancias) y Panoptic FPN proporcionan los valores más robustos, con R^2 superiores a 0.83 tras el posprocesado basado en watershed. Esto los convierte en las opciones más adecuadas para estudios poblacionales, seguimiento de regeneración o análisis de competencia.
3. Los modelos semánticos tienden a fusionar copas y sobreestimar la densidad. Este comportamiento es especialmente acusado en PointRend-Semántico y en menor medida en DeepLabV3+, lo que los hace menos apropiados cuando el objetivo es cuantificar individuos, aunque pueden ser útiles para estimar patrones globales de cobertura.

4. Las inspecciones cualitativas y la tipología de errores confirman los patrones cuantitativos. Los modelos más precisos detectan formas completas y separan individuos contiguos, mientras que los modelos más débiles fragmentan o fusionan copas o las detectan sólo parcialmente y confunden sombras complejas u otros objetos, validando así las conclusiones numéricas.

Líneas futuras de trabajo

1. Incorporación de técnicas avanzadas de data augmentation orientadas a textura y geometría, especialmente útiles para mejorar la detección de copas pequeñas (XS/S).
2. Exploración de arquitecturas más recientes, tales como Mask2Former, SAM adaptado a entrenamiento supervisado o modelos con backbones tipo HRNet o Swin Transformer.
3. Integración de información multitemporal o multispectral, lo que permitiría aumentar la separabilidad entre copa y fondo en condiciones de iluminación complejas.
4. Extensión del análisis a otras especies arbustivas y a paisajes más heterogéneos, con el fin de evaluar la generalización ecológica del enfoque.
5. Mejoras en el posprocesado de detección individual, incorporando métodos basados en gráficos, *instance splitting* o refinamiento geométrico para copas solapadas.
6. Aplicación operativa en programas de seguimiento y gestión, validando los modelos en series temporales o utilizando sensores añadidos (drones, LiDAR terrestre) para generar conjuntos de entrenamiento enriquecidos.

En definitiva, los resultados muestran que los modelos de segmentación profunda, y en particular, Mask R-CNN, constituye una herramienta sólida y precisa para la detección individual de *Juniperus* en alta montaña. La combinación de una alta precisión por instancia, buena coherencia espacial y estimaciones fiables de cobertura y densidad, unida a la capacidad de estas arquitecturas para explotar eficazmente la textura característica de las copas, convierte a este modelo en un candidato idóneo para apoyar estudios ecológicos, labores de conservación y tareas de monitorización a gran escala en entornos de montaña mediterránea. Además, aunque esta arquitectura presenta una menor fidelidad espacial (menor mIoU), la diferencia con el modelo semántico DeepLabV3+ es mínima (varía en 0.01), lo que demuestra que no merece la pena perder la capacidad de detectar individuos, ya que la mejora no es significativa. Por último, Mask R-CNN es el modelo que menos coste computacional presenta, siendo también un punto a favor para esta arquitectura.

7 Anexos

A Otras tablas con métricas representativas

A continuación, se han dejado reflejadas otras métricas que también aportan información y son de utilidad para reforzar la idea de qué modelo es el más robusto (Mask R-CNN).

En las Tablas 17, 18, 24, 20 y 21 se muestran las métricas precisión, recall y F1-score por instancia (según IoU@0.5, IoU@0.75, S-IoU@0.5 y S-IoU@0.75) para los cinco modelos.

Mask R-CNN					
Dataset	Métrica	Thr	Precisión	Recall	F1-score
PI-test ($\theta=0.90$)	IoU	0.50	87.93	82.32	85.03
PI-test ($\theta=0.90$)	IoU	0.75	74.30	69.57	71.86
PI-test ($\theta=0.90$)	S-IoU	0.50	89.32	87.42	88.36
PI-test ($\theta=0.90$)	S-IoU	0.75	85.60	84.17	84.88
FW ($\theta=0.50$)	IoU	0.50	72.60	70.02	71.28
FW ($\theta=0.50$)	IoU	0.75	47.42	45.74	46.57
FW ($\theta=0.50$)	S-IoU	0.50	77.99	77.76	77.87
FW ($\theta=0.50$)	S-IoU	0.75	67.45	69.73	68.57

Tabla 17: Precisión, recall y F1-score en PI-test y FW para Mask R-CNN.

DeepLabV3+					
Dataset	Métrica	Thr	Precisión	Recall	F1-score
PI-test ($\theta=0.75$)	IoU	0.50	87.30	62.75	73.02
PI-test ($\theta=0.75$)	IoU	0.75	57.66	41.45	48.23
PI-test ($\theta=0.75$)	S-IoU	0.50	93.15	84.00	88.34
PI-test ($\theta=0.75$)	S-IoU	0.75	82.26	72.34	76.98
FW ($\theta=0.75$)	IoU	0.50	73.89	39.47	51.45
FW ($\theta=0.75$)	IoU	0.75	36.58	19.54	25.47
FW ($\theta=0.75$)	S-IoU	0.50	87.10	58.77	70.19
FW ($\theta=0.75$)	S-IoU	0.75	69.87	45.84	55.36

Tabla 18: Precisión, recall y F1-score en PI-test y FW para DeepLabV3+.

PointRend-Instancias					
Dataset	Métrica	Thr	Precisión	Recall	F1-score
PI-test ($\theta=0.90$)	IoU	0.50	82.00	87.83	84.81
PI-test ($\theta=0.90$)	IoU	0.75	67.52	72.32	69.84
PI-test ($\theta=0.90$)	S-IoU	0.50	79.57	91.59	85.16
PI-test ($\theta=0.90$)	S-IoU	0.75	68.74	83.14	75.26
FW ($\theta=0.75$)	IoU	0.50	71.11	71.99	71.55
FW ($\theta=0.75$)	IoU	0.75	44.79	45.34	45.06
FW ($\theta=0.75$)	S-IoU	0.50	71.83	76.67	74.17
FW ($\theta=0.75$)	S-IoU	0.75	54.88	63.73	58.98

Tabla 19: Precisión, recall y F1-score en PI-test y FW para PointRend-Instancias.

PointRend-Semántico					
Dataset	Métrica	Thr	Precisión	Recall	F1-score
PI-test ($\theta=0.80$)	IoU	0.50	86.86	68.99	76.90
PI-test ($\theta=0.80$)	IoU	0.75	67.15	53.33	59.45
PI-test ($\theta=0.80$)	S-IoU	0.50	92.88	89.61	91.22
PI-test ($\theta=0.80$)	S-IoU	0.75	87.04	83.83	85.41
FW ($\theta=0.80$)	IoU	0.50	78.49	43.48	55.96
FW ($\theta=0.80$)	IoU	0.75	47.50	26.31	33.87
FW ($\theta=0.80$)	S-IoU	0.50	86.03	55.53	67.49
FW ($\theta=0.80$)	S-IoU	0.75	70.23	44.60	54.55

Tabla 20: Precisión, recall y F1-score en PI-test y FW para PointRend-Semántico.

Panoptic FPN					
Dataset	Métrica	Thr	Precisión	Recall	F1-score
PI-test ($\theta=0.85$)	IoU	0.50	84.44	84.93	84.68
PI-test ($\theta=0.85$)	IoU	0.75	71.18	71.59	71.39
PI-test ($\theta=0.85$)	S-IoU	0.50	84.73	90.32	87.43
PI-test ($\theta=0.85$)	S-IoU	0.75	78.82	85.34	81.95
FW ($\theta=0.60$)	IoU	0.50	74.14	64.77	69.14
FW ($\theta=0.60$)	IoU	0.75	48.99	42.80	45.69
FW ($\theta=0.60$)	S-IoU	0.50	74.73	70.70	72.66
FW ($\theta=0.60$)	S-IoU	0.75	62.90	60.70	61.78

Tabla 21: Precisión, recall y F1-score en PI-test y FW para Panoptic FPN.

En las Tablas 22, 23, 24, 25 y 26 se muestran las métricas ecológicas obtenidas para el conjunto FW antes y después de aplicar watershed.

Mask R-CNN		
Métrica	Baseline	WS Ajustado
RMSE cover	6.62 %	6.62 %
MAE cover	2.52 %	2.52 %
MBE cover	-1.57 %	-1.57 %
R ² cover	0.64	0.64
RMSE dens	16.65	4.90
MAE dens	8.57	3.15
MBE dens	+7.70	+0.15
R ² dens	0.00	0.91
RMSE dens ind/ha	66.13	19.49
R ² dens ind/ha	0.00	0.91

Tabla 22: Métricas ecológicas (cobertura, densidad por imagen y densidad individuo/hectárea) en FW para el modelo Mask R-CNN antes y después de aplicar watershed.

PointRend-Instancias		
Métrica	Baseline	WS Ajustado
RMSE cover	4.49 %	4.49 %
MAE cover	1.90 %	1.90 %
MBE cover	-1.63 %	-1.63 %
R ² cover	0.84	0.84
RMSE dens	29.82	6.97
MAE dens	15.27	3.91
MBE dens	+14.95	+2.07
R ² dens	-2.21	0.83
RMSE dens ind/ha	117.80	27.56
R ² dens ind/ha	-2.21	0.83

Tabla 24: Métricas ecológicas (cobertura, densidad por imagen y densidad individuo/hectárea) en FW para el modelo PointRend-Instancias antes y después de aplicar watershed.

DeepLabV3+		
Métrica	Baseline	WS Ajustado
RMSE cover	2.96 %	2.96 %
MAE cover	1.61 %	1.61 %
MBE cover	-0.91 %	-0.91 %
R ² cover	0.93	0.93
RMSE dens	26.71	10.15
MAE dens	14.84	5.71
MBE dens	+13.27	+2.44
R ² dens	-1.57	0.63
RMSE dens ind/ha	105.51	40.10
R ² dens ind/ha	-1.57	0.63

Tabla 23: Métricas ecológicas (cobertura, densidad por imagen y densidad individuo/hectárea) en FW para el modelo DeepLabV3+ antes y después de aplicar watershed.

PointRend-Semántico		
Métrica	Baseline	WS Ajustado
RMSE cover	6.19 %	6.19 %
MAE cover	2.86 %	2.86 %
MBE cover	-2.74 %	-2.74 %
R ² cover	0.69	0.69
RMSE dens	40.59	12.49
MAE dens	18.93	6.27
MBE dens	+16.73	+1.76
R ² dens	-4.94	0.44
RMSE dens ind/ha	160.38	49.34
R ² dens ind/ha	-4.94	0.44

Tabla 25: Métricas ecológicas (cobertura, densidad por imagen y densidad individuo/hectárea) en FW para el modelo PointRend-Semántico antes y después de aplicar watershed.

Panoptic FPN		
Métrica	Baseline	WS Ajustado
RMSE cover	5.45 %	5.45 %
MAE cover	2.27 %	2.27 %
MBE cover	-2.01 %	-2.01 %
R ² cover	0.76	0.76
RMSE dens	5.82	6.42
MAE dens	3.63	3.90
MBE dens	-2.75	+0.18
R ² dens	0.88	0.85
RMSE dens ind/ha	22.99	25.36
R ² dens ind/ha	0.88	0.85

Tabla 26: Métricas ecológicas (cobertura, densidad por imagen y densidad individuo/hectárea) en FW para el modelo Panoptic FPN antes y después de aplicar watershed.

B Otros gráficos representativos

A continuación, se muestran otros gráficos que aportan información adicional acerca de la evaluación de las cinco arquitecturas.

La Figura 28 y la Figura 29 ejemplifican más situaciones en las que los diferentes modelos cometen errores de detección de coronas.




Figura 28: Hotspot 1 extraído de la imagen `Img_1.tif` (conjunto FW). La región muestra un área con copas pequeñas y medianas sobre un fondo rocoso de alta textura, donde todos los modelos, aunque en diferente medida, tienden a perder copas pequeñas y a detectar parcialmente copas más grandes.




Figura 29: Hotspot 2 correspondiente a la imagen `Img_1.tif` (conjunto FW). La zona presenta copas dispersas alrededor de estructuras rocosas y elementos antrópicos, lo que genera un escenario propenso a falsos positivos y pérdidas de contorno. Todos los modelos presentan una pérdida de copas o detecciones parciales. En concreto, DeepLabV3+ incorpora parte de las rocas como vegetación.

Referencias

- [1] A. Lamprecht, P. R. Semenchuk, K. Steinbauer, M. Winkler, and H. Pauli, "Climate change leads to accelerated transformation of high-elevation vegetation in the central alps," *New Phytologist*, vol. 220, no. 2, pp. 447–459, 2018.
- [2] A. A. Grigoriev, Y. V. Shalaumova, D. S. Balakin, O. V. Erokhina, S. Y. Abdulmanova, P. A. Moiseev, and J. J. Camarero, "Alpine shrubification: juniper encroachment into tundra in the ural mountains," *Forests*, vol. 13, no. 12, p. 2106, 2022.
- [3] CU Denver College of Liberal Arts and Sciences, "Climate change impacts on alpine plant communities," May 2024. <https://clas.ucdenver.edu/ges/2024/05/07/climate-change-impacts-alpine-plant-communities>.
- [4] M. Carrer, R. Dibona, A. L. Prendin, and M. Brunetti, "Recent waning snowpack in the alps is unprecedented in the last six centuries," *Nature Climate Change*, vol. 13, no. 2, pp. 155–160, 2023. <https://www.nature.com/articles/s41558-022-01575-3>.
- [5] S. B. Rumpf, K. Hülber, G. Klonner, D. Moser, M. Schütz, J. Wessely, W. Willner, N. E. Zimmermann, and S. Dullinger, "Range dynamics of mountain plants decrease with elevation," *Proceedings of the National Academy of Sciences*, vol. 115, no. 8, pp. 1848–1853, 2018.
- [6] C. P. Bueno de Mesquita, S. C. Elmendorf, J. G. Smith, and K. N. Suding, "Shifting alpine plant distributions with global change: Testing the environmental matching hypothesis," *Arctic, Antarctic, and Alpine Research*, vol. 56, no. 1, p. 2393443, 2024.
- [7] F. Anthelme, J.-C. Villaret, and J.-J. Brun, "Shrub encroachment in the alps gives rise to the convergence of sub-alpine communities on a regional scale," *Journal of Vegetation Science*, vol. 18, no. 3, pp. 355–362, 2007.
- [8] Y.-C. Shi, Q. Chen, M.-R. Du, S.-L. Xiao, S.-F. Li, X.-F. Wang, Q. Li, and C. Q. Tang, "Community and population characteristics and future potential habitats under climate change of juniperus species in yunnan, southwestern china," *Plants*, vol. 14, no. 17, p. 2754, 2025.
- [9] X. Lu, E. Liang, Y. Wang, F. Babst, S. W. Leavitt, and J. Julio Camarero, "Past the climate optimum: Recruitment is declining at the world's highest juniper shrublines on the tibetan plateau," *Ecology*, vol. 100, no. 2, p. e02557, 2019.
- [10] R. Khaldi, S. Tabik, S. Puertas-Ruiz, J. P. de Giles, J. A. H. Correa, R. Zamora, and D. A. Segura, "Individual mapping of large polymorphic shrubs in high mountains using satellite images and deep learning," *International Journal of Applied Earth Observation and Geoinformation*, vol. 134, p. 104191, 2024. <https://www.sciencedirect.com/science/article/pii/S1569843224005478>.
- [11] B. Ayhan, C. Kwan, B. Budavari, L. Kwan, Y. Lu, D. Perez, J. Li, D. Skarlatos, and M. Vlachos, "Vegetation detection using deep learning and conventional methods," *Remote Sensing*, vol. 12, no. 15, p. 2502, 2020.
- [12] D. Barhate, S. Pathak, B. K. Singh, A. Jain, and A. K. Dubey, "A systematic review of machine learning and deep learning approaches in plant species detection," *Smart Agricultural Technology*, vol. 9, p. 100605, 2024.

- [13] Y. Wu, A. Kirillov, F. Massa, W.-Y. Lo, and R. Girshick, "Detectron2," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*, 2019. <https://github.com/facebookresearch/detectron2>.
- [14] E. Guirado, J. Blanco-Sacristan, E. Rodriguez-Caballero, S. Tabik, D. Alcaraz-Segura, J. Martinez-Valderrama, and J. Cabello, "Mask r-cnn and obia fusion improves the segmentation of scattered vegetation in very high-resolution optical sensors," *Sensors*, vol. 21, no. 1, p. 320, 2021. <https://www.mdpi.com/1424-8220/21/1/320>.
- [15] C. Zhang, P. M. Atkinson, C. George, Z. Wen, M. Diazgranados, and F. Gerard, "Identifying and mapping individual plants in a highly diverse high-elevation ecosystem using uav imagery and deep learning," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 169, pp. 280–291, 2020. <https://www.sciencedirect.com/science/article/pii/S0924271620302720>.
- [16] A. Retallack, G. Finlayson, B. Ostendorf, and M. Lewis, "Using deep learning to detect an indicator arid shrub in ultra-high-resolution uav imagery," *Ecological Indicators*, vol. 145, p. 109698, 2022. <https://www.sciencedirect.com/science/article/pii/S1470160X22011712>.
- [17] Y. Xie, Z. Sha, and M. Yu, "Remote sensing imagery in vegetation mapping: a review," *Journal of plant ecology*, vol. 1, no. 1, pp. 9–23, 2008. <https://academic.oup.com/jpe/article/1/1/9/1132900>.
- [18] M. M. Zaka and A. Samat, "Advances in remote sensing and machine learning methods for invasive plants study: A comprehensive review," *Remote Sens*, vol. 16, p. 3781, 2024. <https://www.mdpi.com/2072-4292/16/20/3781>.
- [19] C. Matyukira and P. Mhangara, "Advances in vegetation mapping through remote sensing and machine learning techniques: a scientometric review," *European Journal of Remote Sensing*, vol. 57, no. 1, p. 2422330, 2024. <https://www.tandfonline.com/doi/full/10.1080/22797254.2024.2422330>.
- [20] T. J. Givnish, "Deep learning sharpens vistas on biodiversity mapping," *Proceedings of the National Academy of Sciences*, vol. 121, no. 41, p. e2416358121, 2024. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11474093/>.
- [21] B. Chang, F. Li, Y. Hu, H. Yin, Z. Feng, and L. Zhao, "Application of uav remote sensing for vegetation identification: a review and meta-analysis," *Frontiers in Plant Science*, vol. 16, p. 1452053, 2025. <https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2025.1452053/full>.
- [22] K. Yan, S. Gao, G. Yan, X. Ma, X. Chen, P. Zhu, J. Li, S. Gao, J.-P. Gastellu-Etchegorry, R. B. Myneni, *et al.*, "A global systematic review of the remote sensing vegetation indices," *International Journal of Applied Earth Observation and Geoinformation*, vol. 139, p. 104560, 2025. <https://www.sciencedirect.com/science/article/pii/S1569843225002079>.
- [23] R. Khaldi, P.-R. Sergio, A. S. Domingo, Z. Regino, T. Siham, P. d. G. Julio, and H. C. José Antonio, "Junipermapper: Ai for shrub delineation (data)," 2023. Dataset.
- [24] M. Belgiu and L. Drăguț, "Random forest in remote sensing: A review of applications and future directions," *ISPRS journal of photogrammetry and remote sensing*, vol. 114, pp. 24–31, 2016.

- [25] A. E. Maxwell, T. A. Warner, and F. Fang, "Implementation of machine-learning classification in remote sensing: An applied review," *International journal of remote sensing*, vol. 39, no. 9, pp. 2784–2817, 2018.
- [26] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [27] A. Kirillov, R. Girshick, K. He, and P. Dollár, "Panoptic feature pyramid networks," pp. 6399–6408, 2019.
- [28] K. He, G. Gkioxari, P. Dollár, and R. Girshick, "Mask r-cnn," in *Proceedings of the IEEE international conference on computer vision*, pp. 2961–2969, 2017.
- [29] S. Ren, K. He, R. Girshick, and J. Sun, "Faster r-cnn: Towards real-time object detection with region proposal networks," *Advances in neural information processing systems*, vol. 28, 2015. <https://arxiv.org/abs/1506.01497>.
- [30] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, "Microsoft coco: Common objects in context," in *European conference on computer vision*, pp. 740–755, Springer, 2014.
- [31] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, and H. Adam, "Encoder-decoder with atrous separable convolution for semantic image segmentation," in *Proceedings of the European conference on computer vision (ECCV)*, pp. 801–818, 2018.
- [32] M. Cordts, M. Omran, S. Ramos, T. Rehfeld, M. Enzweiler, R. Benenson, U. Franke, S. Roth, and B. Schiele, "The cityscapes dataset for semantic urban scene understanding," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 3213–3223, 2016.
- [33] A. Kirillov, Y. Wu, K. He, and R. Girshick, "Pointrend: Image segmentation as rendering," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 9799–9808, 2020.
- [34] O. L. F. de Carvalho, O. A. de Carvalho Júnior, C. R. e. Silva, A. O. de Albuquerque, N. C. Santana, D. L. Borges, R. A. T. Gomes, and R. F. Guimarães, "Panoptic segmentation meets remote sensing," *Remote Sensing*, vol. 14, no. 4, p. 965, 2022.
- [35] F. H. Wagner, M. P. Ferreira, A. Sanchez, M. C. Hirye, M. Zortea, E. Gloor, O. L. Phillips, C. R. de Souza Filho, Y. E. Shimabukuro, and L. E. Aragão, "Individual tree crown delineation in a highly diverse tropical forest using very high resolution satellite images," *ISPRS journal of photogrammetry and remote sensing*, vol. 145, pp. 362–377, 2018.
- [36] E. Ayrey and D. J. Hayes, "The use of three-dimensional convolutional neural networks to interpret lidar for forest inventory," *Remote Sensing*, vol. 10, no. 4, p. 649, 2018.
- [37] G. de Andrade Ferreira, J. M. S. M. Viveiros, G. B. Santoro, V. C. Amaral, M. P. Ferreira, P. H. S. Brancalion, and P. G. Molin, "Solution for diagnostics of biological invasion in terrestrial ecosystems: how can deep learning help biodiversity conservation?," *Journal for Nature Conservation*, p. 127066, 2025.

- [38] M. Machefer, F. Lemarchand, V. Bonnefond, A. Hitchins, and P. Sidiropoulos, "Mask r-cnn refitting strategy for plant counting and sizing in uav imagery," *Remote Sensing*, vol. 12, no. 18, p. 3015, 2020.
- [39] Z. Guan, X. Miao, Y. Mu, Q. Sun, Q. Ye, and D. Gao, "Forest fire segmentation from aerial imagery data using an improved instance segmentation model," *Remote Sensing*, vol. 14, no. 13, p. 3159, 2022.
- [40] G. Wang, J. Chen, L. Mo, P. Wu, and X. Yi, "Lightweight land cover classification via semantic segmentation of remote sensing imagery and analysis of influencing factors," *Frontiers in Environmental Science*, vol. 12, p. 1329517, 2024.
- [41] M. Campos-Taberner, F. J. García-Haro, B. Martínez, E. Izquierdo-Verdiguier, C. Atzberger, G. Camps-Valls, and M. A. Gilabert, "Understanding deep learning in land use classification based on sentinel-2 time series," *Scientific reports*, vol. 10, no. 1, p. 17188, 2020.
- [42] S. Manfreda, M. F. McCabe, P. E. Miller, R. Lucas, V. Pajuelo Madrigal, G. Mallinis, E. Ben Dor, D. Helman, L. Estes, G. Ciruolo, *et al.*, "On the use of unmanned aerial systems for environmental monitoring," *Remote sensing*, vol. 10, no. 4, p. 641, 2018. <https://www.mdpi.com/2072-4292/13/3/501>.
- [43] O. L. F. De Carvalho, O. A. de Carvalho Júnior, A. O. De Albuquerque, N. C. Santana, D. L. Borges, A. S. Luiz, R. A. T. Gomes, and R. F. Guimarães, "Multispectral panoptic segmentation: Exploring the beach setting with worldview-3 imagery," *International Journal of Applied Earth Observation and Geoinformation*, vol. 112, p. 102910, 2022.
- [44] Z. Chang, H. Li, D. Chen, Y. Liu, C. Zou, J. Chen, W. Han, S. Liu, and N. Zhang, "Crop type identification using high-resolution remote sensing images based on an improved deeplabv3+ network," *Remote Sensing*, vol. 15, no. 21, p. 5088, 2023.
- [45] A. A. Gharahbagh, V. Hajihashemi, J. J. Machado, and J. M. R. Tavares, "Land cover classification model using multispectral satellite images based on a deep learning synergistic semantic segmentation network," *Sensors*, vol. 25, no. 7, p. 1988, 2025.
- [46] B. Zhu, D. Yu, X. Xiao, J. Shen, Z. Cui, Y. Su, A. Li, and D. Li, "Ap-pointrend: An improved network for building extraction via high-resolution remote sensing images," *Remote Sensing*, vol. 17, no. 9, p. 1481, 2025. <https://www.mdpi.com/2072-4292/17/9/1481>.
- [47] R. Geirhos, P. Rubisch, C. Michaelis, M. Bethge, F. A. Wichmann, and W. Brendel, "Imagenet-trained cnns are biased towards texture; increasing shape bias improves accuracy and robustness," in *International conference on learning representations*, 2018.
- [48] K. Hermann, T. Chen, and S. Kornblith, "The origins and prevalence of texture bias in convolutional neural networks," *Advances in neural information processing systems*, vol. 33, pp. 19000–19015, 2020.
- [49] Observatorio de Cambio Global de Sierra Nevada (OSE), "Observatorio de cambio global de sierra nevada," s.f. <https://obsnev.es/en/>.
- [50] Observatorio de Cambio Global de Sierra Nevada (OSE), "Sierra nevada information — why sierra nevada is ideal to analyze global change," s.f. <https://obsnev.es/en/informacion/>.

- [51] NASA, "Sierra nevada en espanha y portugal," 2003. https://commons.wikimedia.org/wiki/File:Sierra_Nevada_en_Espanha_y_Portugal.jpg.
- [52] Cultidelta, "Juniperus sabina," n.d. <https://www.cultidelta.com/especies/juniperus-sabina/>.
- [53] J. Sigro, M. Cisneros, A. J. Perez-Luque, C. Perez-Martinez, and T. Vegas-Vilarrubia, "Trends in temperature and precipitation at high and low elevations in the main mountain ranges of the iberian peninsula (1894–2020): The sierra nevada and the pyrenees," *International Journal of Climatology*, vol. 44, no. 9, pp. 2897–2920, 2024. <https://www.researchgate.net/publication/380629757>.
- [54] C. Adler, P. Wester, I. Bhatt, C. Huggel, G. Insarov, M. Morecroft, V. Muccione, A. Prakash, I. Alcántara-Ayala, S. K. Allen, *et al.*, "Cross-chapter paper 5: mountains," *Climate change 2022: impacts, adaptation, and vulnerability*, 2023. <https://www.ipcc.ch/report/ar6/wg2/chapter/ccp4/>.
- [55] E. Ali, W. Cramer, J. Carnicer, E. Georgopoulou, N. J. Hilmi, G. Le Cozannet, and P. Lionello, "Cross-chapter paper 4: Mediterranean region," *Climate change*, pp. 2233–2272, 2022. <https://www.ipcc.ch/report/ar6/wg2/chapter/ccp5/>.
- [56] D. Garcia, R. Zamora, J. A. Hódar, and J. M. Gómez, "Age structure of juniperus communis l. in the iberian peninsula: conservation of remnant populations in mediterranean mountains," *Biological Conservation*, vol. 87, no. 2, pp. 215–220, 1999. <https://www.sciencedirect.com/science/article/abs/pii/S0006320798000597>.
- [57] J. Blanco-Sacristán, E. Guirado, J. L. Molina-Pardo, J. Cabello, E. Giménez-Luque, and D. Alcaraz-Segura, "Remote sensing-based monitoring of postfire recovery of persistent shrubs: The case of juniperus communis in sierra nevada (spain)," *Fire*, vol. 6, no. 1, p. 4, 2022. <https://www.mdpi.com/2571-6255/6/1/4>.
- [58] J. C. Pérez-Girón, S. Puertas-Ruiz, R. Zamora, and D. Alcaraz-Segura, "Tracing five decades of junipers' responses to global changes in mediterranean high mountains," *Global Ecology and Conservation*, vol. 58, p. e03426, 2025. <https://www.sciencedirect.com/science/article/pii/S2351989425000277>.
- [59] Cadena SER, "La foto negra de la nieve en las montañas españolas," enero 2025. <https://cadenaser.com/nacional/2025/01/16/la-foto-negra-de-la-nieve-en-las-montanas-espanolas-cadena-ser/>.
- [60] S. Van der Walt, J. L. Schönberger, J. Nunez-Iglesias, F. Boulogne, J. D. Warner, N. Yager, E. Gouillart, and T. Yu, "scikit-image: image processing in python," *PeerJ*, vol. 2, p. e453, 2014. <https://peerj.com/articles/453/>.
- [61] J. Reback, W. McKinney, J. Van Den Bossche, T. Augspurger, P. Cloud, A. Klein, S. Hawkins, M. Roeschke, J. Tratner, C. She, *et al.*, "pandas-dev/pandas: Pandas 1.0.5," *Zenodo*, 2020.
- [62] H. W. Kuhn, "The hungarian method for the assignment problem," *Naval research logistics quarterly*, vol. 2, no. 1-2, pp. 83–97, 1955.
- [63] K. D. Rand, I. Grytten, M. Pavlović, C. Kanduri, and G. K. Sandve, "Bionumpy: array programming for biology," *Nature Methods*, vol. 21, no. 12, pp. 2198–2199, 2024.

- [64] G. Bradski, "The opencv library.," *Dr. Dobbs's Journal: Software Tools for the Professional Programmer*, vol. 25, no. 11, pp. 120–123, 2000.